Sistemas Paralelos y Distribuidos

Máster en Ciencia y Tecnología Informática

Máster Universitario en Matemática Aplicada y Computacional

Curso 2023-2024

Sistemas de altas prestaciones en entornos distribuidos

Alejandro Calderón Mateos y Félix García Carballeira

Grupo de Arquitectura de Computadores

alejandro.calderon@uc3m.es

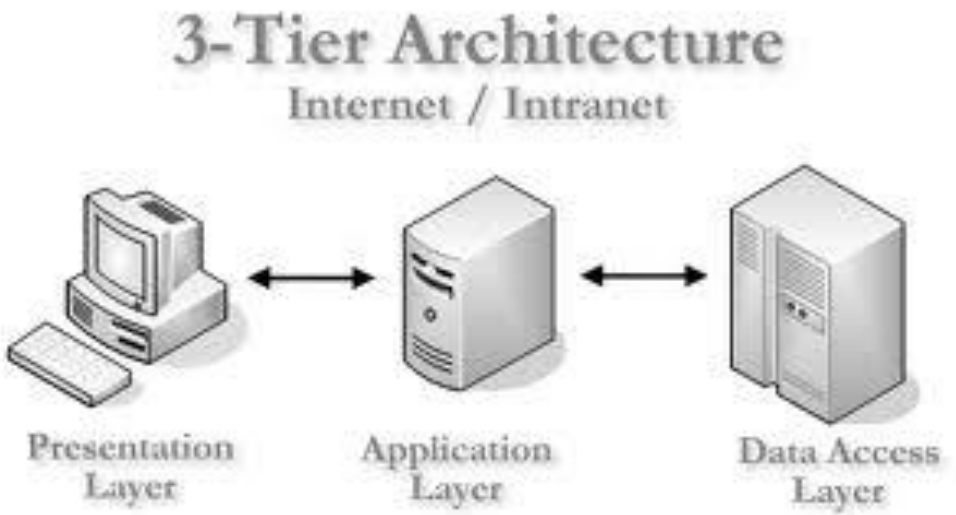

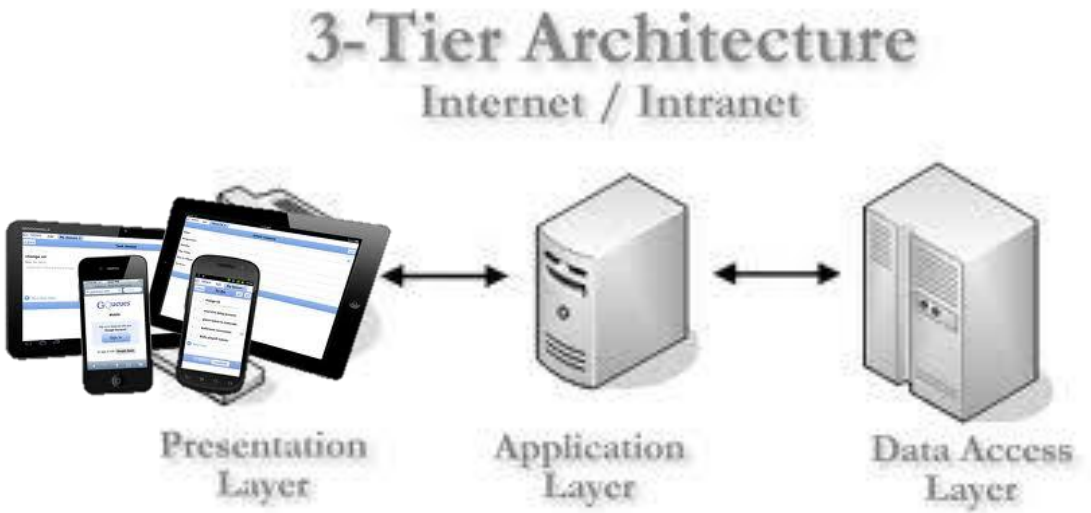

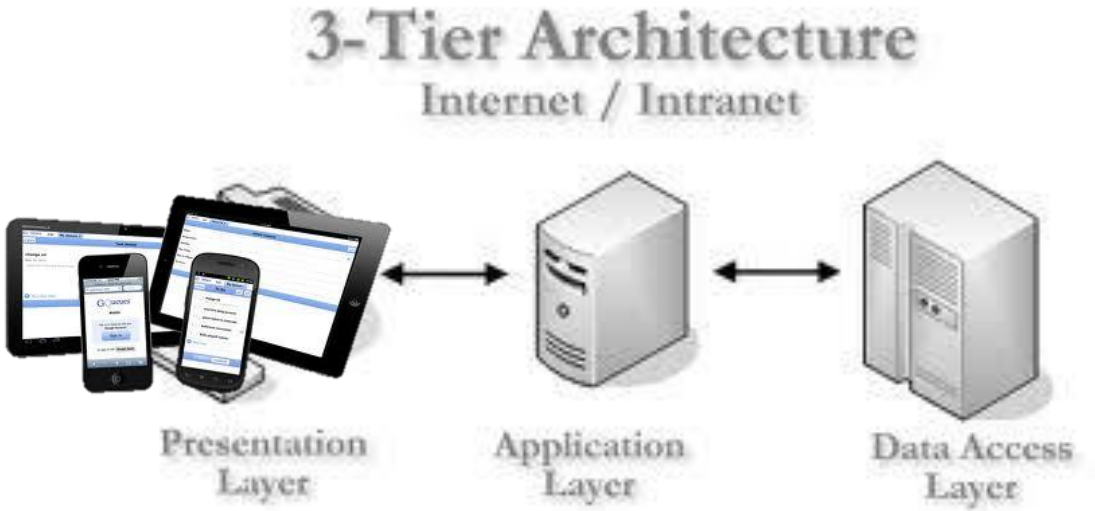

https://adoc.pub/aplikasi-sistem-penjualan-pada-toko-batik-candi-luhur-berbas.html

3-Tier Architecture

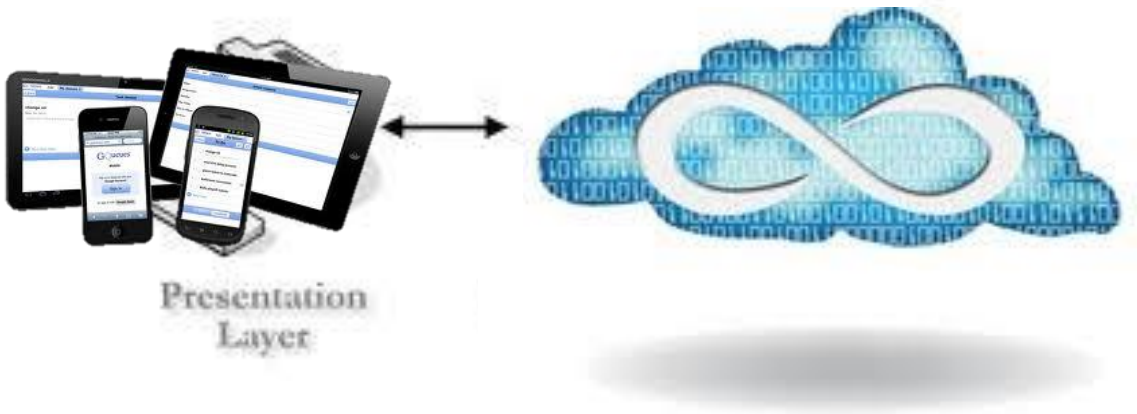

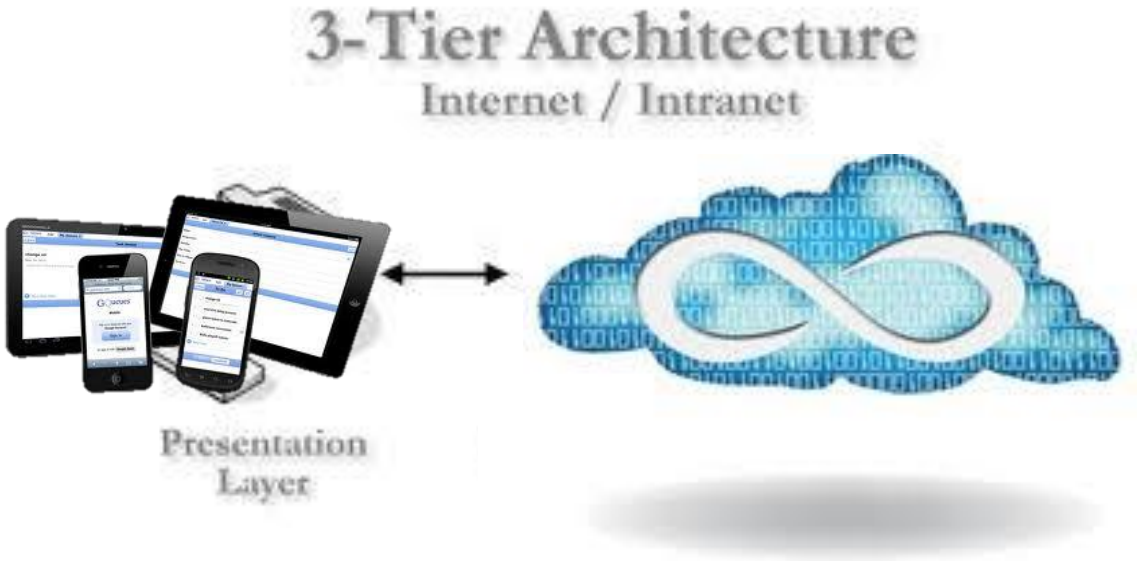
3-Tier Architecture
Internet / Intranet
Presentation Layer

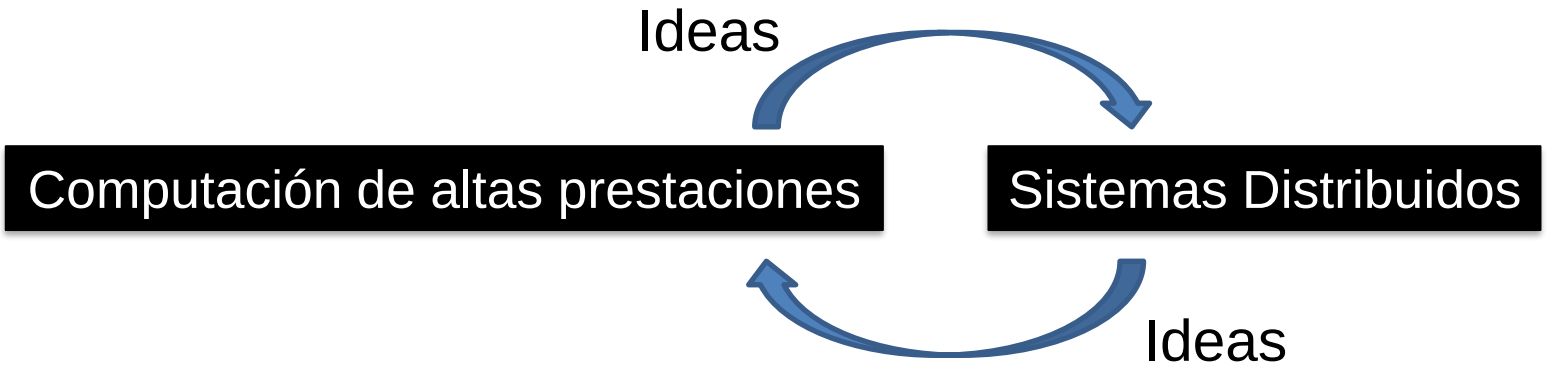
Ideas
Computación de altas prestaciones
Sistemas Distribuidos
Ideas

Agenda

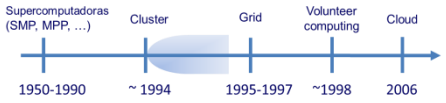

Introducción a la computación de altas prestaciones

- Qué, dónde y cómo
- Hardware y software

Evolución de la computación de altas prestaciones

- Plataformas
- Tendencias

Agenda

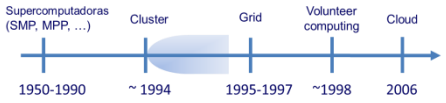

Introducción a la computación de altas prestaciones

- Qué, dónde y cómo
- Hardware y software

Evolución de la computación de altas prestaciones

- Plataformas
- Tendencias

Computación de altas prestaciones

- La computación de altas prestaciones o HPC (*High Performance Computing*) se centra principalmente en la velocidad.
- El objetivo es conseguir la máxima cantidad de cómputo posible en la mínima cantidad de tiempo.

¿Dónde se necesita?

[Culler99]

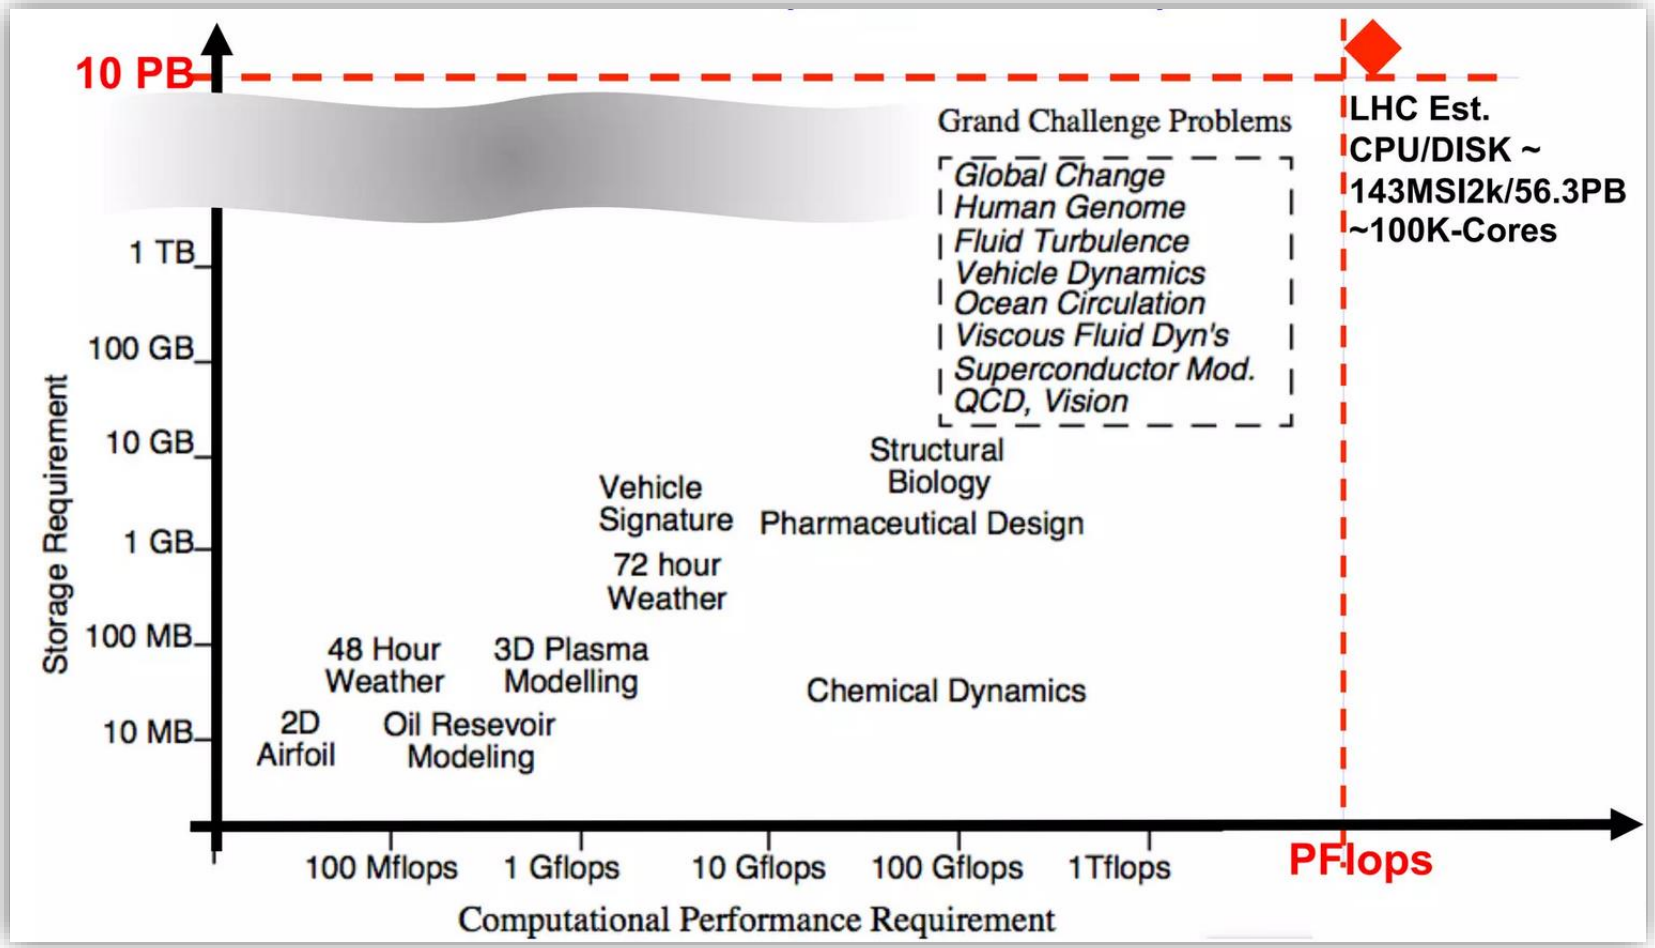

https://www.slideshare.net/hlshih/high-performance-computing-building-blocks-production-perspective

Ejemplo 1/2: Predicción meteorológica…

(http://www.businessinsider.com/97-million-supercomputer-in-the-uk-2014-10)

- Inversión en nuevo **supercomputador** para **mejorar previsiones meteorológicas**:
  - Con **precisión de 300 metros** se podrá indicar incidencias relacionadas con niebla, rachas de viento, etc.
  - Predicciones con un **margen de 1 hora** en lugar de 3 horas

- Impacto:
  - Supondrá **97 millones de libras** (156,9 millones de dólares)
  - Estará operacional en el 2017, inicio en 2014.
  - El supercomputador pesa lo que **11 autobuses de doble planta**

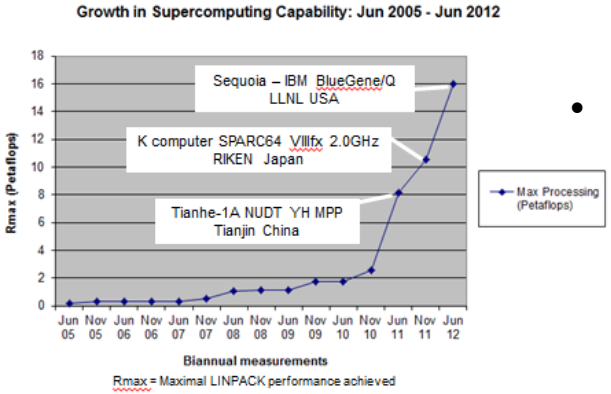

- Capacidad computacional:
  - Será **13 veces más potente** que el que se usa ahora.
  - Tiene una capacidad aproximada de **16 petaFLOPS**.

http://observer.com/2012/09/red-bus-turns-heads-at-christies-london-themed-sale/
http://futurememes.blogspot.com.es/2012/08/supercomputing-16-petaflops-schmetaflops.html

Ejemplo 2/2: Big Hero 6 (2014)…

(http://www.engadget.com/2014/10/18/disney-big-hero-6/)

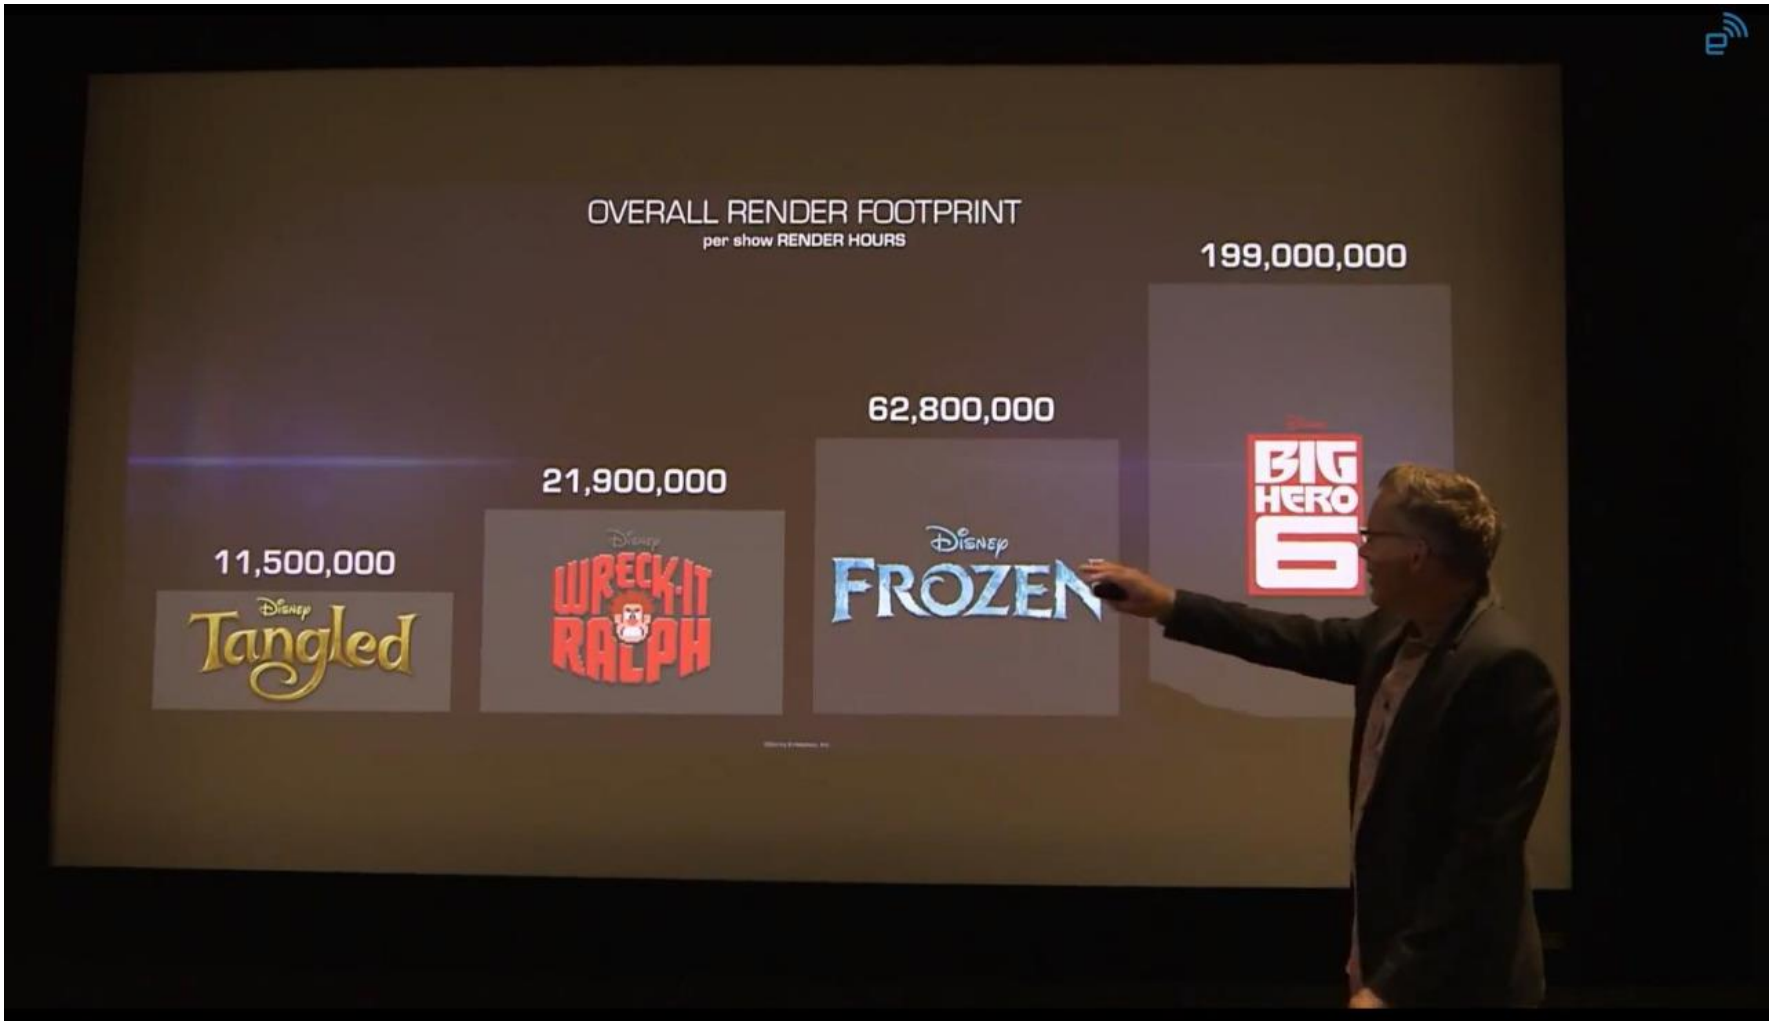

http://technologybehindmagic.tumblr.com/post/100635699626/the-number-of-rendering-hours-that-went-into-big

Ejemplo 2/2: Big Hero 6 (2014)…

(http://www.engadget.com/2014/10/18/disney-big-hero-6/)

- **To manage that cluster and the 400,000-plus computations it processes per day (roughly about 1.1 million computational hours per day), his team created software called Coda, which treats the four render farms like a single supercomputer**. If one or more of those thousands of jobs fails, Coda alerts the appropriate staffers via an iPhone app.
- **The film takes 199 million core-hours (181 days) of rendering**. To put the enormity of this computational effort into perspective, Hendrickson says that **Hyperion "could render *Tangled (2010)* from scratch every 10 days."**
- **If that doesn't drive the power of Disney's proprietary renderer home, then consider this: San Fransokyo contains around 83,000 buildings, 260,000 trees, 215,000 streetlights and 100,000 vehicles (plus thousands of crowd extras generated by a tool called Denizen).** What's more, all of the detail you see in the city is actually based off assessor data for lots and street layouts from the real San Francisco.

¿Cómo se consigue más velocidad?

¿Cómo se consigue más velocidad?

- Mejores algoritmos
  - $O(n^2)$, viajante, …

¿Cómo se consigue más velocidad?

- Mejores algoritmos
  - $O(n^2)$, viajante, …

- Mejores procesadores (mejoras en la tecnología)
  - CPU a 10 GHz, 510 TB de RAM, …

¿Cómo se consigue más velocidad?

- Mejores algoritmos
  - $O(n^2)$, viajante, …

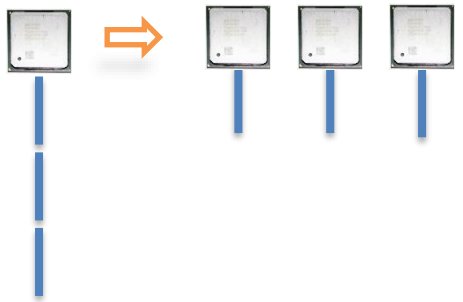

- Mejores procesadores (mejoras en la tecnología)
  - CPU a 10 GHz, 510 TB de RAM, …

- Paralelismo (mejoras en el uso de la tecnología actual)
  - Speedup, Ley de Amdahl, …

¿Eso del paralelismo qué implica?

- Mejores algoritmos
  - $O(n^2)$, viajante, …
- Mejores procesadores (mejoras en la tecnología)
  - CPU a 10 GHz, 510 TB de RAM, …
- Paralelismo (mejoras en el uso de la tecnología actual)
  - Speedup, Ley de Amdahl, …

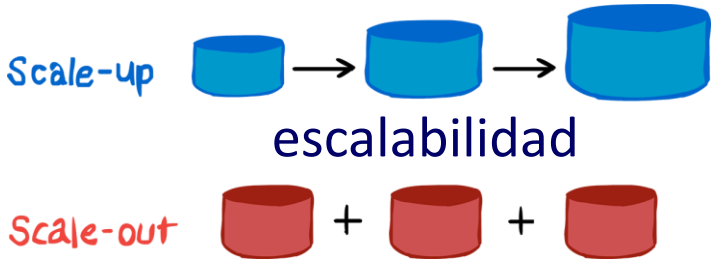

https://cdn.turbonomic.com/wp-content/uploads/ScaleUpScaleOut.png

Tipos de paralelismo

- Tareas independientes:

Tipos de paralelismo

- Tareas independientes:

- Tareas cooperativas:
  - *Pipeline*
  - Coordinación (*mutex* y *conditions*)

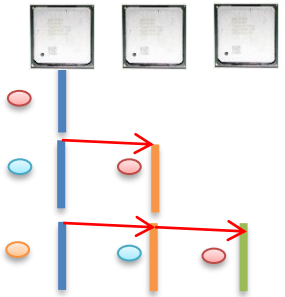

Tipos de paralelismo

- Tareas independientes:

- Tareas cooperativas:
  - *Pipeline*
  - Coordinación (*mutex* y *conditions*)

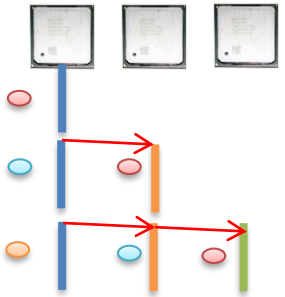

- Tareas competitivas:
  - Código secuencial :-S

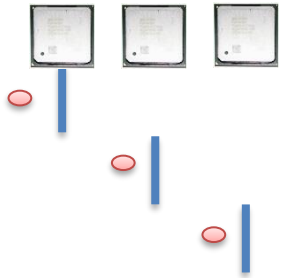

Speedup

- La mejora (o *speedup*) en la ejecución paralela con n elementos de cómputo será:

  speedup = tiempo_de_ejecución (1) / tiempo_de_ejecución (**n**)

Speedup

- La mejora (o *speedup*) en la ejecución paralela con n elementos de cómputo será:

  speedup = tiempo_de_ejecución (1) / tiempo_de_ejecución (**n**)

- No siempre se obtiene un *speedup* ideal:

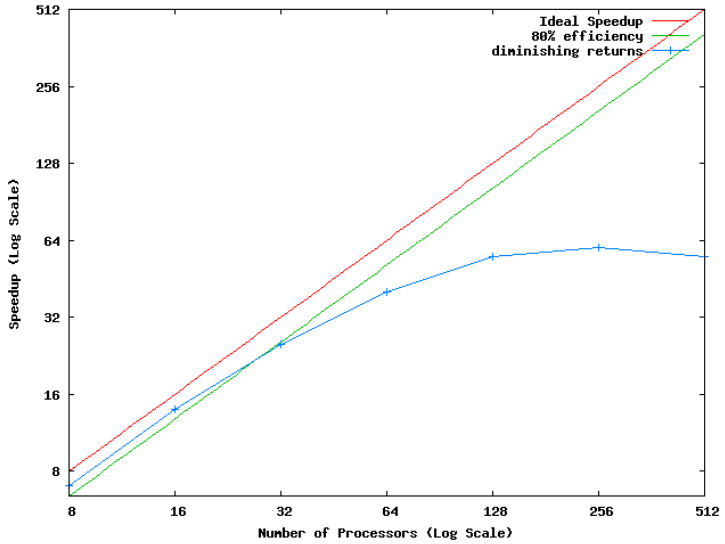

http://www.nathankerr.com/projects/parallel-gis-processing/alternative_approaches_to_parallel_gis_processing.html

Ley de Amdahl

- Ley de Amdahl:

  "el *speedup* teórico está limitado por la fracción secuencial s del programa"

$$speedup <= \frac{1}{s + \frac{(1-s)}{\mathbf{n}}}$$

SI **n**↑ ENTONCES ***speedup*** **~ 1 / s**

Ley de Amdahl

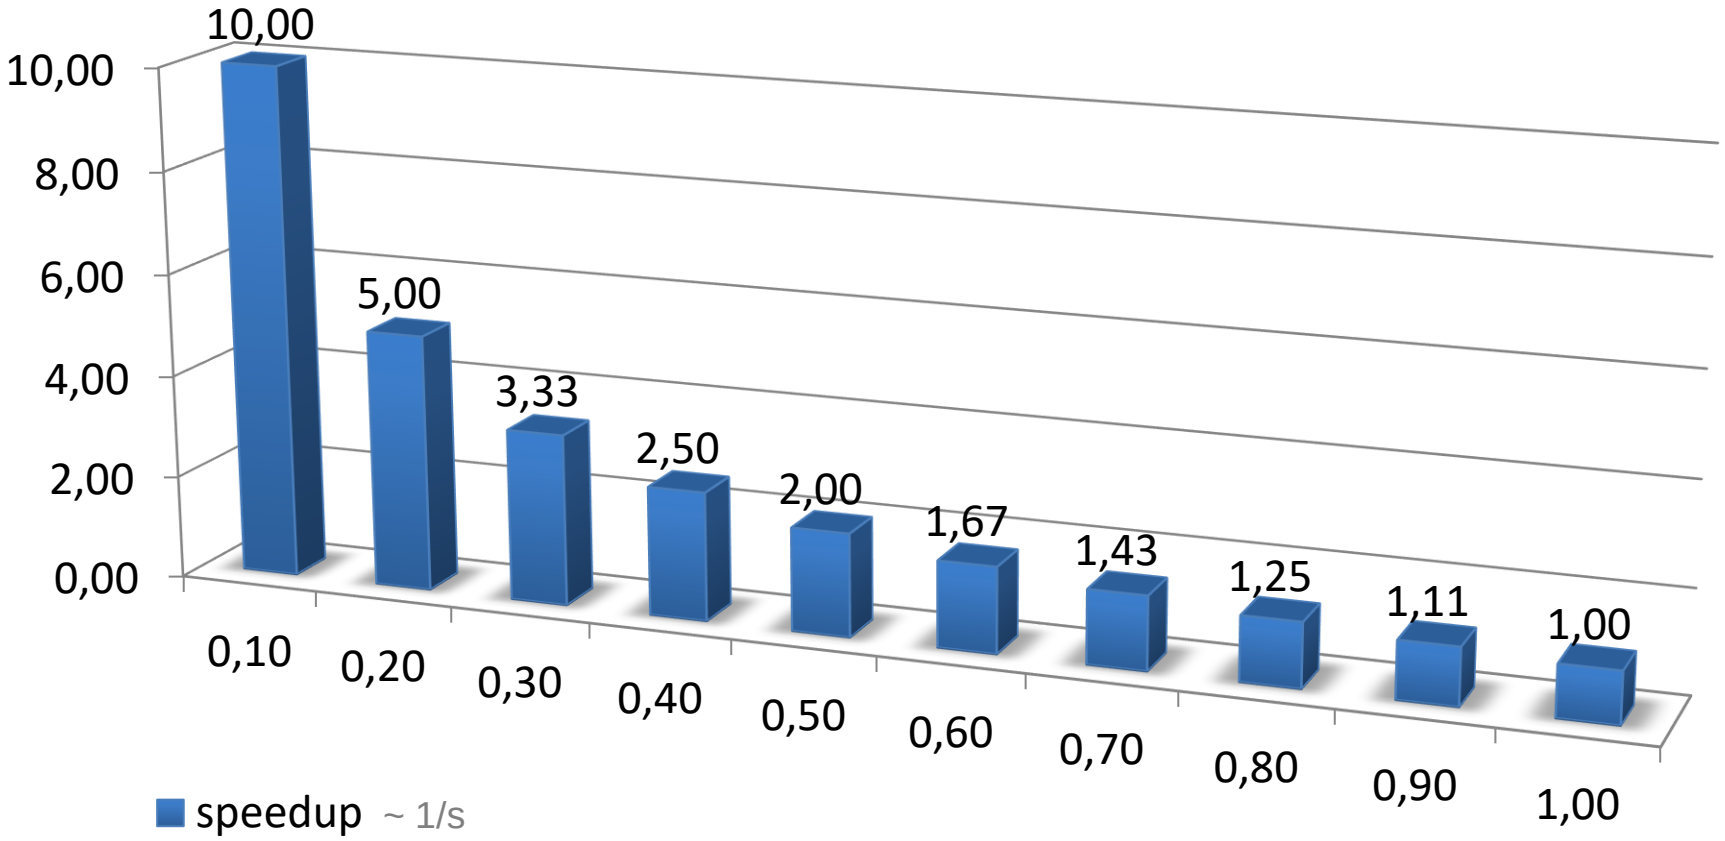

¿Eso del paralelismo ayuda?

caso de estudio: genoma humano

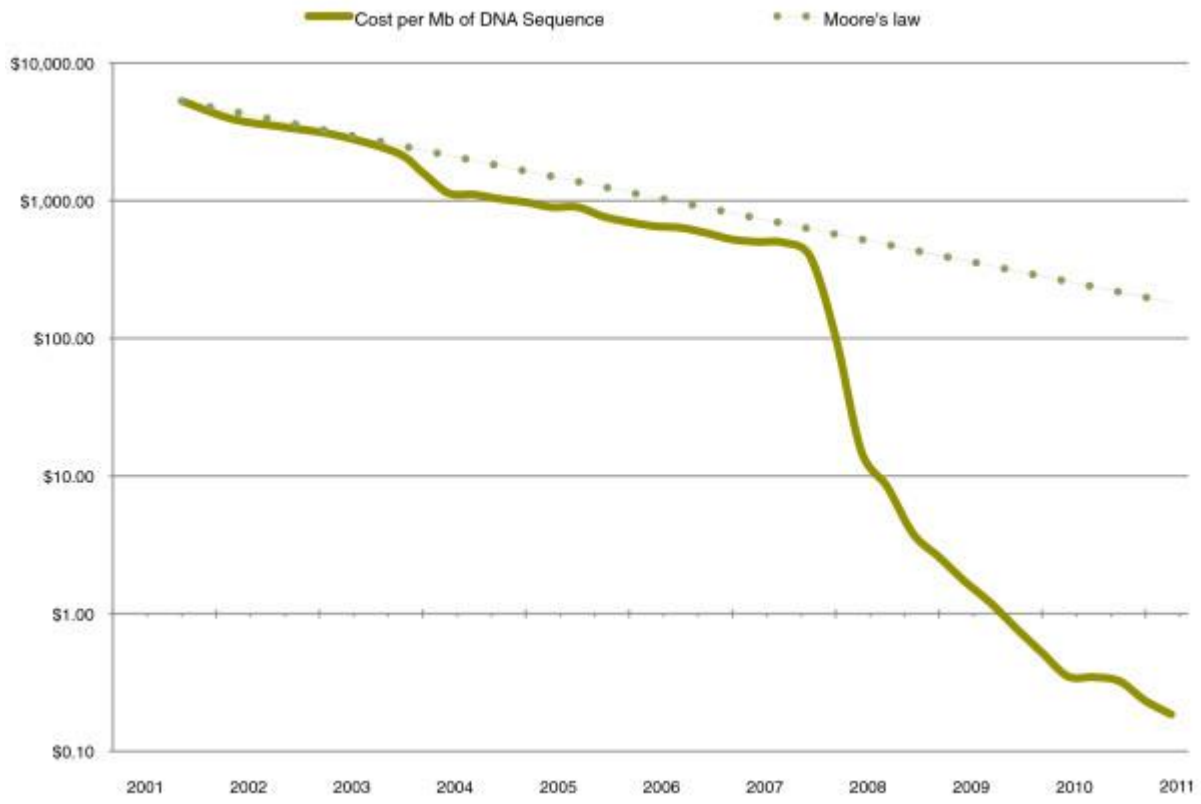

http://genomebiology.com/2011/12/8/125
http://pressroom.nvidia.com/easyir/customrel.do?easyirid=A0D622CE9F579F09&prid=878712&releasejsp=release_157

¿Eso del paralelismo ayuda?

caso de estudio: genoma humano

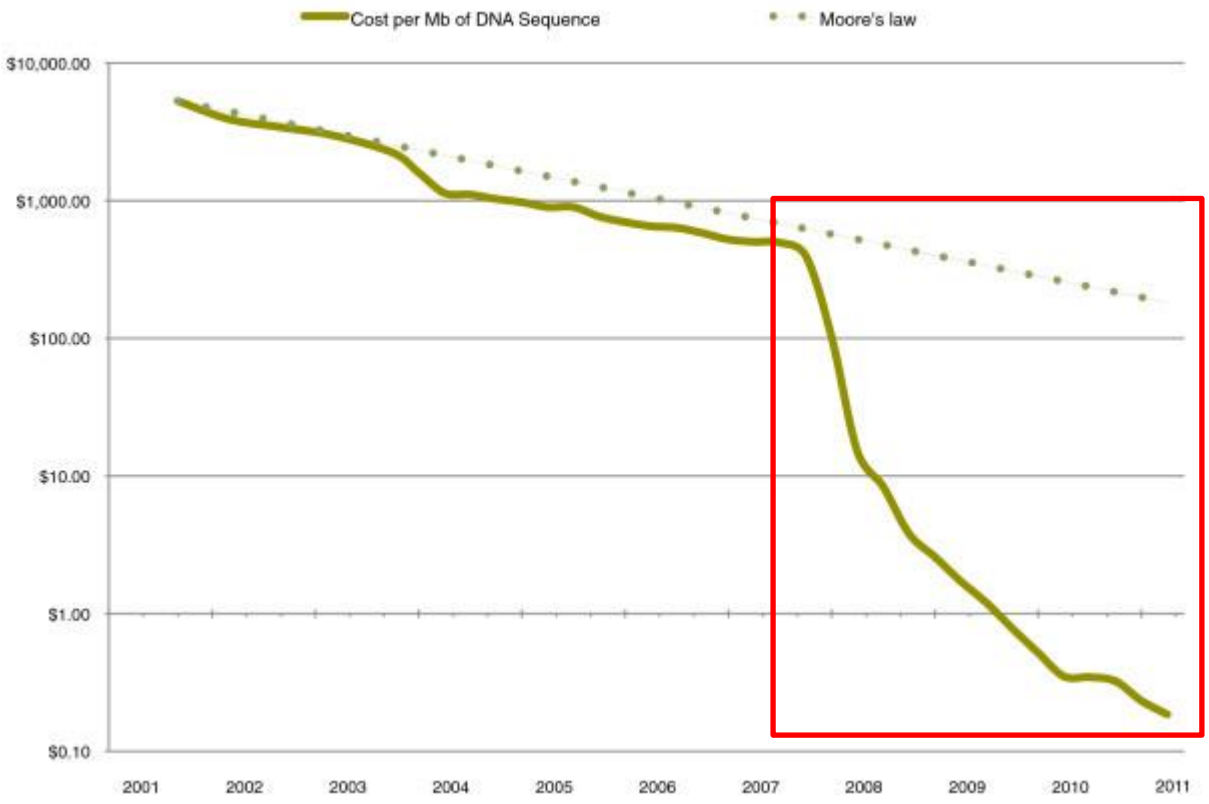

Yes!

http://genomebiology.com/2011/12/8/125
http://pressroom.nvidia.com/easyir/customrel.do?easyirid=A0D622CE9F579F09&prid=878712&releasejsp=release_157

Computación de altas prestaciones

- Mejores algoritmos
  - $O(n^2)$, viajante, …
- Mejores procesadores
  - 10 GHz, 510 TB, …
- Paralelismo
  - Ley de Amdahl, …

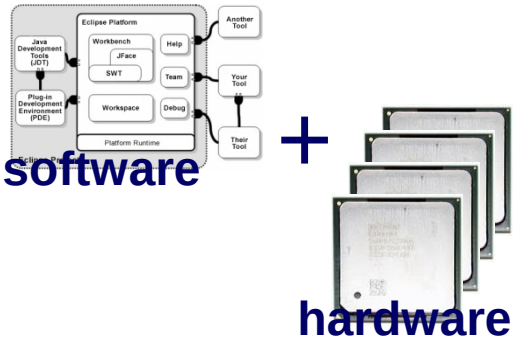

Agenda

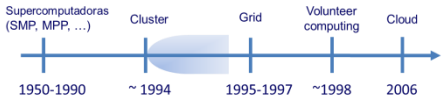

Introducción a la computación de altas prestaciones
- Qué, dónde y cómo
- Hardware y software

Evolución de la computación de altas prestaciones
- Plataformas
- Tendencias

Plataforma hardware y software

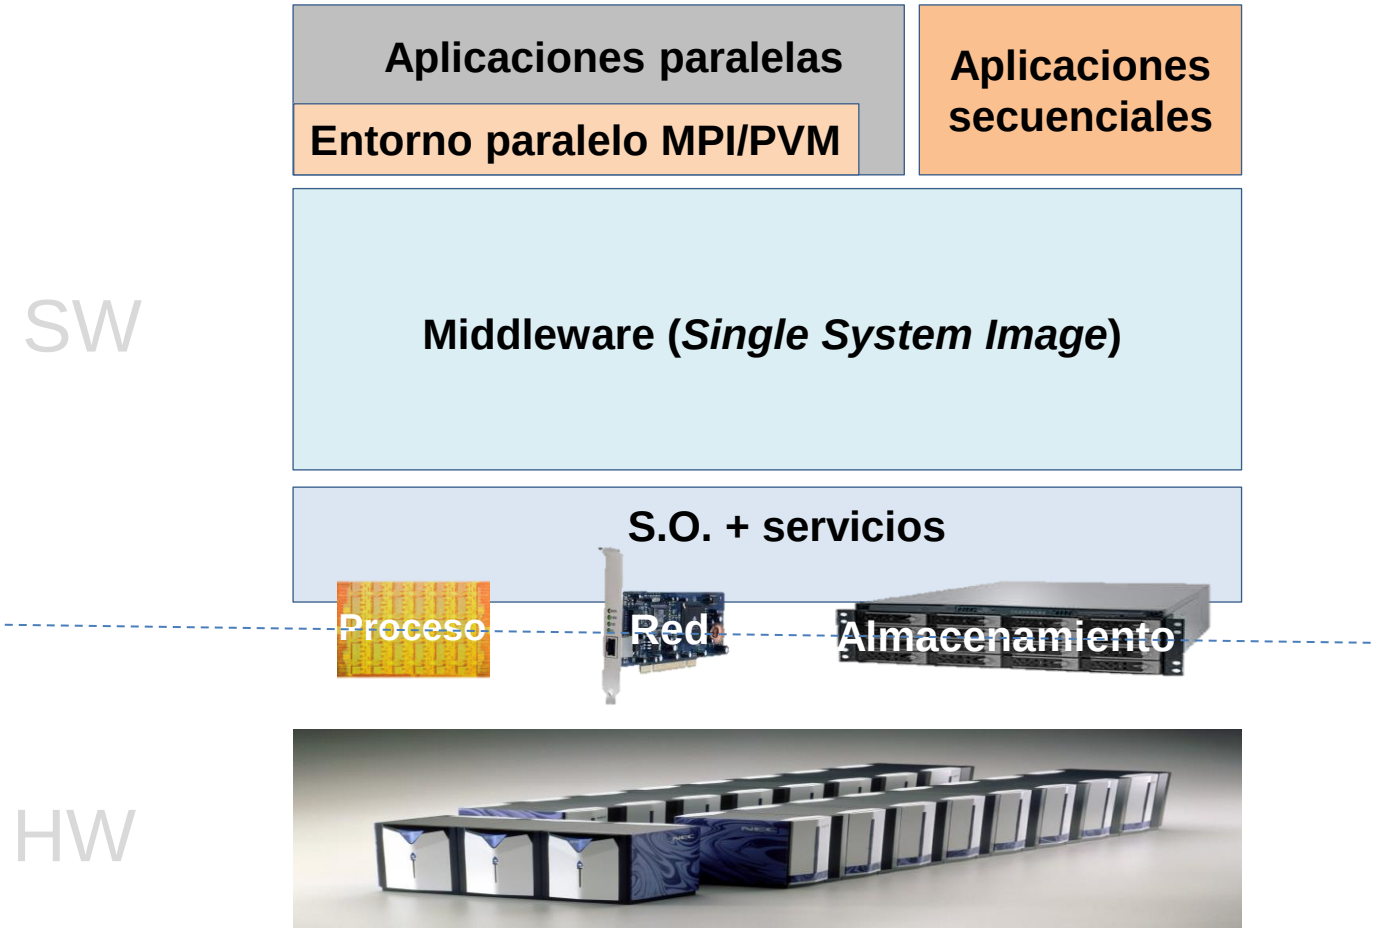

Computador de altas prestaciones

Plataforma hardware

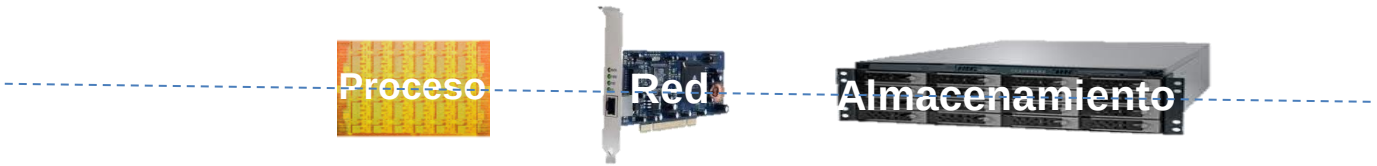

HW

- **Procesamiento**
  (vectorial vs multiprocesador)
- **Memoria**
  (compartida vs distribuida)

Plataforma hardware

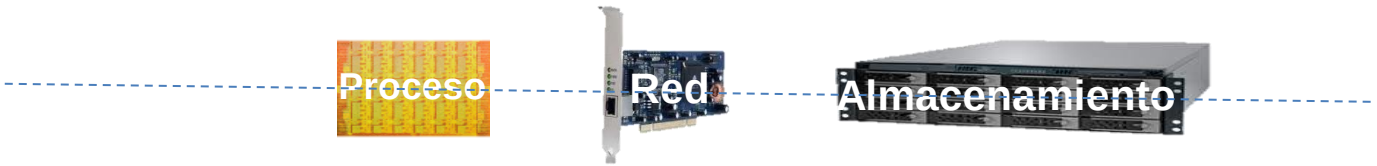

HW

- **Procesamiento**
  (vectorial vs multiprocesador)
- **Memoria**
  (compartida vs distribuida)

Taxonomía de Flynn

http://www.buyya.com/microkernel/chap1.pdf

	Single Instruction	Multiple Instruction
Single Data	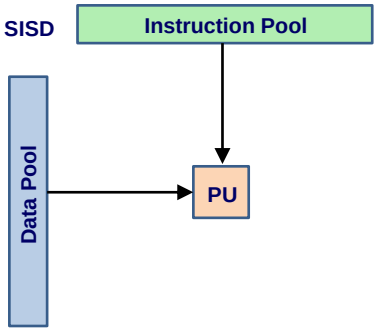	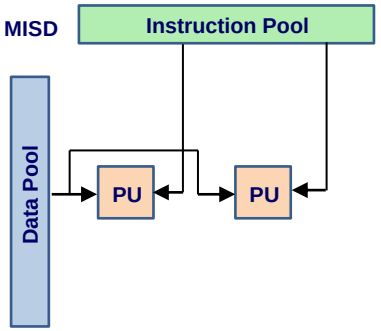
Multiple Data	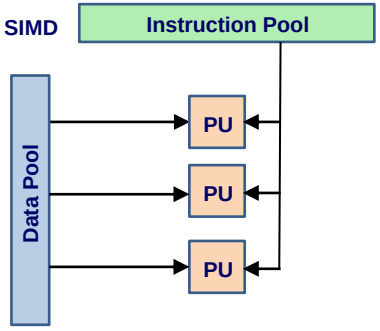	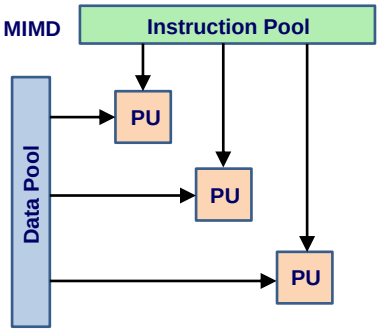

Taxonomía de Flynn

	Single Instruction	Multiple Instruction
Single Data	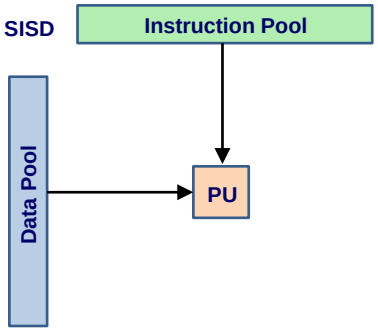	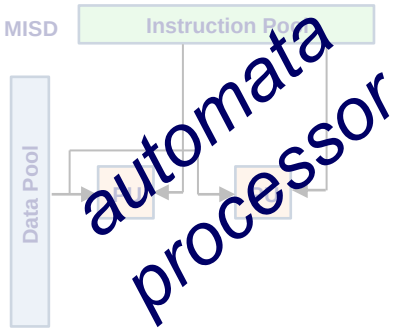
Multiple Data	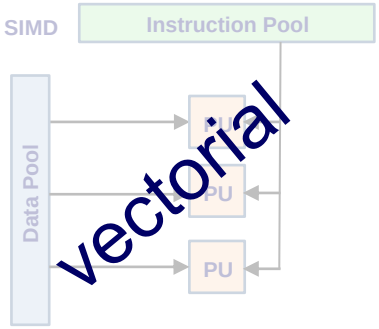	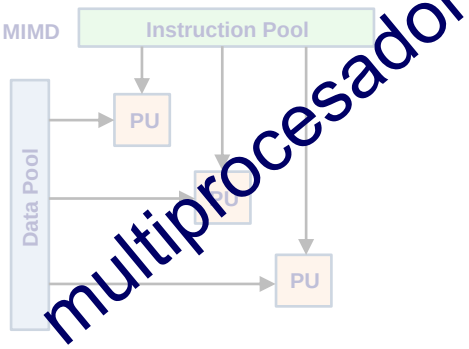

Taxonomía de Flynn

	Single Instruction	Multiple Instruction
Single Data	SISD 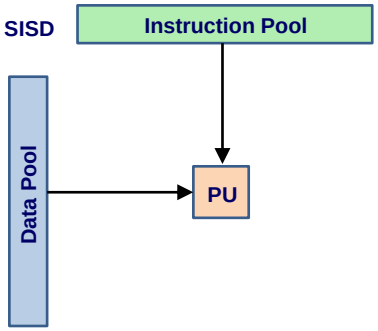	MISD 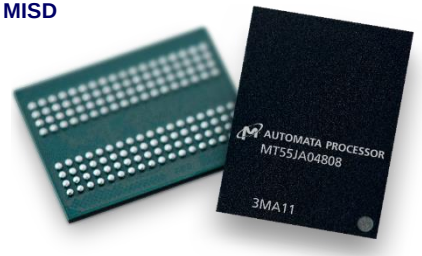 *automata processor*
Multiple Data	SIMD  vectorial	MIMD 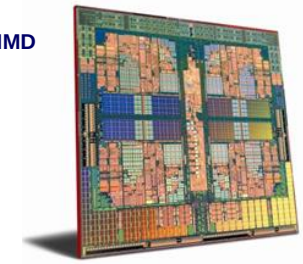 multiprocesador

Plataforma hardware

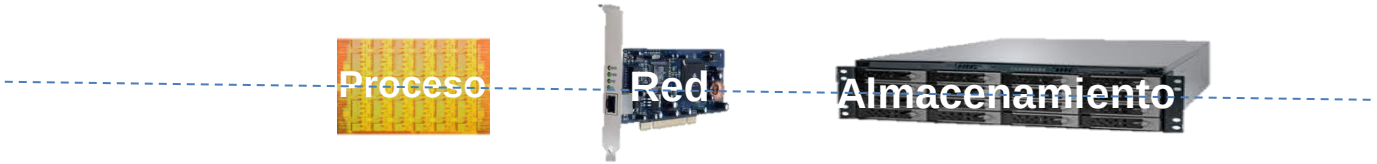

HW

- **Procesamiento**
  (vectorial vs multiprocesador)
- **Memoria**
  (compartida vs distribuida)

Acceso a memoria

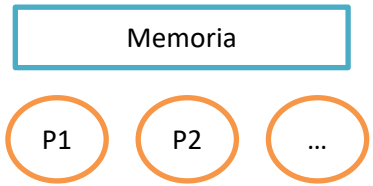

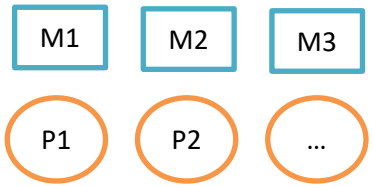

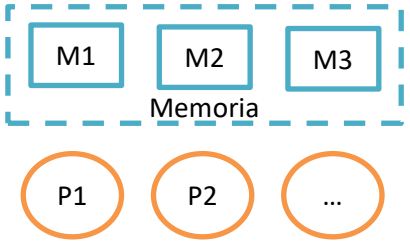

- Memoria compartida (UMA)
- Memoria distribuida (MD)
- Memoria lógicamente compartida (NUMA)

Acceso a memoria

Visión lógica de la memoria
(comunicación/sincronización)

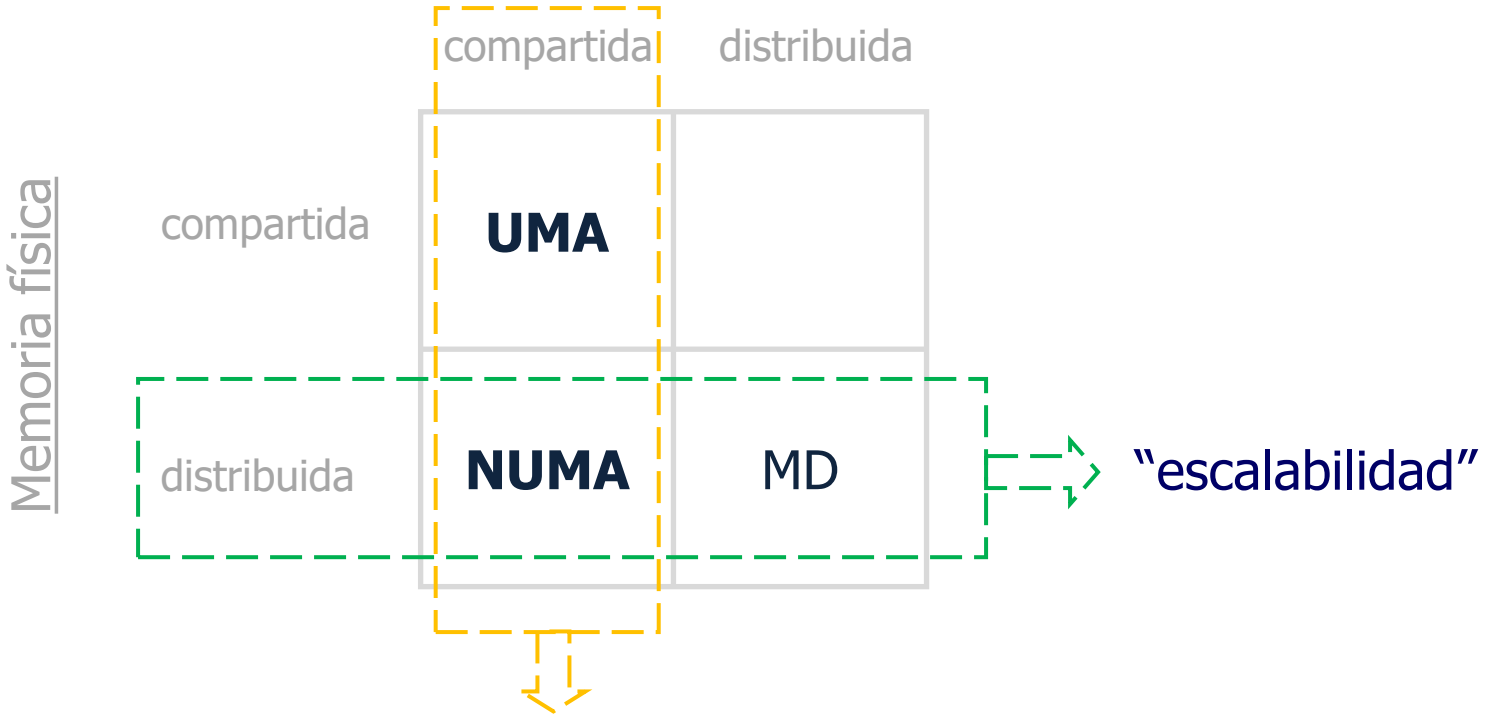

Plataforma software

SW

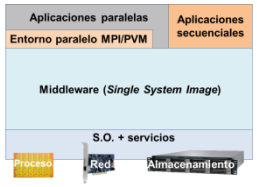

- Vectoriales
  - Uso de instrucciones especiales
- Multiprocesador
  - UMA, NUMA
    - OpenMP, …
  - M. Distribuida
    - MPI, …

Plataforma software

SW

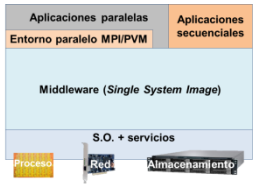

- Vectoriales
  - Uso de instrucciones especiales
- Multiprocesador
  - UMA, NUMA
    - OpenMP, …
  - M. Distribuida
    - MPI, …

Cómo es OpenMP

```
#include <omp.h>
#include <stdio.h>
#include <stdlib.h>

int main (int argc, char *argv[])
{
   #pragma omp parallel private(nthreads, tid)
   {
      int tid = omp_get_thread_num();
      printf("Hello World from thread = %d\n", tid);

      #pragma omp master
      {
         int nthreads = omp_get_num_threads();
         printf("Number of threads = %d\n", nthreads);
      }
   }
}
```

Plataforma software

SW

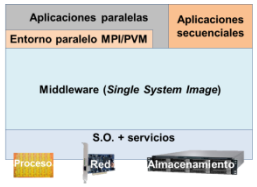

- Vectoriales
  - Uso de instrucciones especiales
- Multiprocesador
  - UMA, NUMA
    - OpenMP, …
  - M. Distribuida
    - MPI, …

Qué es MPI

- MPI es una interfaz de paso de mensaje que representa un esfuerzo prometedor de mejorar la disponibilidad de un software altamente eficiente y portable para satisfacer las necesidades actuales en la computación de alto rendimiento a través de la definición de un estándar de paso de mensajes universal.

William D. Gropp et al.

Principales pilares de MPI

- Portabilidad:
  - Definido independiente de plataforma paralela.
  - Útil en arquitecturas paralelas heterogéneas.
- Eficiencia:
  - Definido para aplicaciones multihilo (*multithread*)
  - Sobre una comunicación fiable y eficiente.
  - Busca el máximo de cada plataforma.
- Funcionalidad:
  - Fácil de usar por cualquier programador que ya haya usado cualquier biblioteca de paso de mensajes.

Implementaciones de MPI

Open MPI 4.1.6 (30/9/2023)

- http://www.open-mpi.org/
- FT-MPI + LA-MPI + LAM/MPI + PACX-MPI

MPICH 4.1.2 (8/6/2023)

- http://www.mpich.org/
- Argonne National Laboratory & University of Chicago

Cómo es MPI

```
#include <stdio.h>
#include "mpi.h"

main(int argc, char **argv)
{
        int node,size;
        int tam = 255;
        char name[255];

        MPI_Init(&argc, &argv);

        MPI_Comm_size (MPI_COMM_WORLD, &size);
        MPI_Comm_rank(MPI_COMM_WORLD, &node);
        MPI_Get_processor_name(name, &tam);
        printf("Hola Mundo2 del proceso %d de %d procesos (%s)\n", node, size, name);

        MPI_Finalize();
}
```

Cómo es MPI: uso interactivo

uc3m15672@login2:~/tmp> mpicc -g -o hello hello.c

uc3m15672@login2:~/tmp> cat > machines

```
login1
login2
login3
login4
^D
```

uc3m15672@login2:~/tmp> mpirun -np 4 -machinefile machines ~/tmp/hello

```
Hola Mundo2 del proceso 0 de 4 procesos (login1)
Hola Mundo2 del proceso 3 de 4 procesos (login4)
Hola Mundo2 del proceso 1 de 4 procesos (login2)
Hola Mundo2 del proceso 2 de 4 procesos (login3)
```

Cómo es MPI: uso de SLURM (1)

uc3m15672@login2:~/tmp> cat hello.cmd

```
#!/bin/bash
#SBATCH --job-name=mpi
#SBATCH --output=mpi_%j.out
#SBATCH --error=mpi_%j.err
#SBATCH --nodes=4
#SBATCH --exclusive
#SBATCH --time=00:05:00
#SBATCH --qos=debug

export HOME_PATH=/home/uc3m15/uc3m15672
scontrol show hostnames "${SLURM_JOB_NODELIST}"          > ${HOME_PATH}/tmp/machine_file
mpirun -np 2 -machinefile ${HOME_PATH}/tmp/machine_file  ${HOME_PATH}/tmp/hello
```

Cómo es MPI: uso de SLURM (2)

```
uc3m15672@login2:~/tmp> sbatch hello.cmd
Submitted batch job 25372807

uc3m15672@login2:~/tmp> squeue
             JOBID PARTITION     NAME     USER ST       TIME  NODES NODELIST(REASON)
          25372807 sequentia hello.cm uc3m1567 PD       0:00      1 (None)


uc3m15672@login2:~/tmp> squeue
             JOBID PARTITION     NAME     USER ST       TIME  NODES NODELIST(REASON)
          25372807 sequentia hello.cm uc3m1567 R        0:05      1 s07r2b72

uc3m15672@login2:~/tmp> squeue
             JOBID PARTITION     NAME     USER ST       TIME  NODES NODELIST(REASON)
```

Cómo es MPI: uso de SLURM (3)

uc3m15672@login2:~/tmp> cat slurm-25372807.out
Hola Mundo2 del proceso 1 de 2 procesos (s07r1b08)
Hola Mundo2 del proceso 0 de 2 procesos (s07r1b05)

Cómo es MPI: uso de SLURM (4)

```
uc3m15672@login2:~/tmp> bsc_queues
  queue         job          max          wall clock
  name          nodes        cores                time
------------    -----        -----     ----------------
debug             16          768           00:10:00
interactive        1            4           02:00:00
bsc               50         2400           48:00:00
RES Class A      200         9600           72:00:00
PRACE            400        19200           72:00:00
```

MPI 2.2 – 4.1rc

(http://mpi-forum.org/docs/)

- Estructuras de datos
  - Tipos de datos (básicos, vectores, compuestos, …)
  - Grupo de procesos (grupos, comunicadores, …)
- Paso de mensajes
  - Llamadas punto a punto (bloqueantes, …)
  - Llamadas colectivas (*bcast*, *scatter*, *gather*, …)
- Entrada y salida
  - Gestión de ficheros (apertura, cierre, …)
  - Gestión de contenidos (vistas, punteros, …)
- Procesos
  - Gestión de procesos (creación, …)
  - *Profiling*

Send-receive en MPI

https://www.pinterest.es/pin/497577458813063755/

```
#include <stdio.h>
#include "mpi.h"

main(int argc, char **argv)  {
        int node,size;
        int tam = 255;
        char name[255];
        int num = 10;

        MPI_Init(&argc,&argv);
        MPI_Comm_size(MPI_COMM_WORLD, &size );
        MPI_Comm_rank(MPI_COMM_WORLD, &node);

        if (node == 0)
              MPI_Send(&num, 1, MPI_INT,  1, 0, MPI_COMM_WORLD);
        else
              MPI_Recv(&num, 1, MPI_INT,  0, 0, MPI_COMM_WORLD);

        MPI_Finalize();
}
```

Send-receive en MPI

https://www.pinterest.es/pin/497577458813063755/

```
#include <stdio.h>
#include "mpi.h"

main(int argc, char **argv)  {
        int node,size;
        int tam = 255;
        char name[255];
        int num = 10;

        MPI_Init(&argc,&argv);
        MPI_Comm_size(MPI_COMM_WORLD, &size );
        MPI_Comm_rank(MPI_COMM_WORLD, &node);

        if (node == 0)
              MPI_Send(&num, 1, MPI_INT,  1, 0, MPI_COMM_WORLD);
        else
              MPI_Recv(&num, 1, MPI_INT,  0, 0, MPI_COMM_WORLD);

        MPI_Finalize();
}
```

Dato a enviar

Número de elementos

Tipo de datos

- MPI_CHAR
- MPY_BYTE
- MPI_INT
- MPI_FLOAT
- ….
- Tipos de datos derivados

Send-receive en MPI

https://www.pinterest.es/pin/497577458813063755/

```
#include <stdio.h>
#include "mpi.h"

main(int argc, char **argv)  {
        int node,size;
        int tam = 255;
        char name[255];
        int num = 10;

        MPI_Init(&argc,&argv);
        MPI_Comm_size(MPI_COMM_WORLD, &size );
        MPI_Comm_rank(MPI_COMM_WORLD, &node);

        if (node == 0)
              MPI_Send(&num, 1, MPI_INT,  1, 0, MPI_COMM_WORLD);
        else
              MPI_Recv(&num, 1, MPI_INT,  0, 0, MPI_COMM_WORLD);

        MPI_Finalize();
}
```

Dato a enviar

Número de elementos

Tipo de datos

- MPI_CHAR
- MPY_BYTE
- MPI_INT
- MPI_FLOAT
- ….
- Tipos de datos derivados

Proceso destinatario

Etiqueta asociada al mensaje

Comunicador

Send-receive en MPI

https://www.pinterest.es/pin/497577458813063755/

```
#include <stdio.h>
#include "mpi.h"

main(int argc, char **argv)  {
        int node,size;
        int tam = 255;
        char name[255];
        int num = 10;

        MPI_Init(&argc,&argv);
        MPI_Comm_size(MPI_COMM_WORLD, &size );
        MPI_Comm_rank(MPI_COMM_WORLD, &node);

        if (node == 0)
              MPI_Send(&num, 1, MPI_INT,  1, 0, MPI_COMM_WORLD);
        else
              MPI_Recv(&num, 1, MPI_INT,  0, 0, MPI_COMM_WORLD);

        MPI_Finalize();
}
```

Proceso origen del mensaje

Etiqueta asociada al mensaje

Comunicador

Operaciones colectivas

https://www.pinterest.es/pin/497577458813063755/

MPI_Bcast

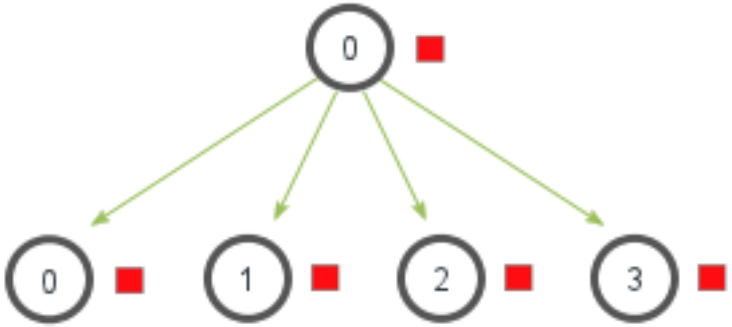

MPI_Scatter

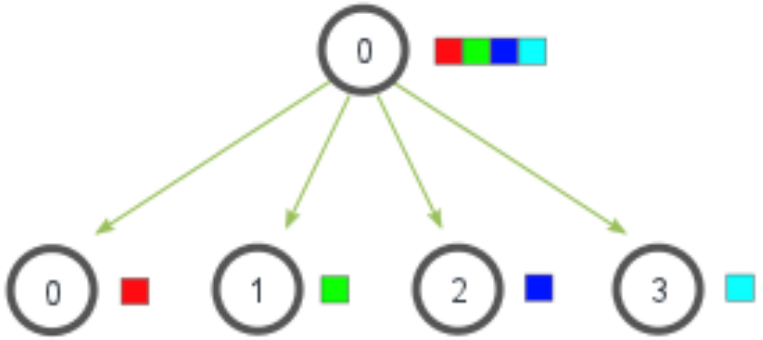

MPI_Gather

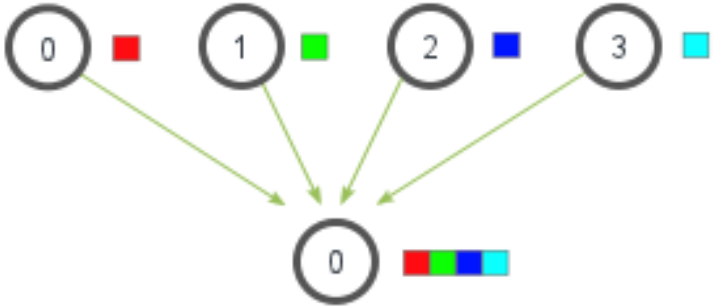

MPI_Allgather

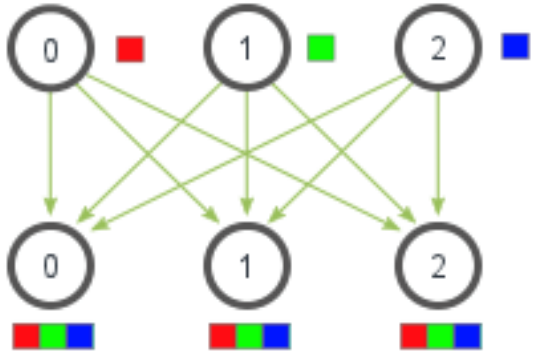

Operaciones colectivas de reducción

https://www.pinterest.es/pin/497577458813063755/

MPI_Reduce

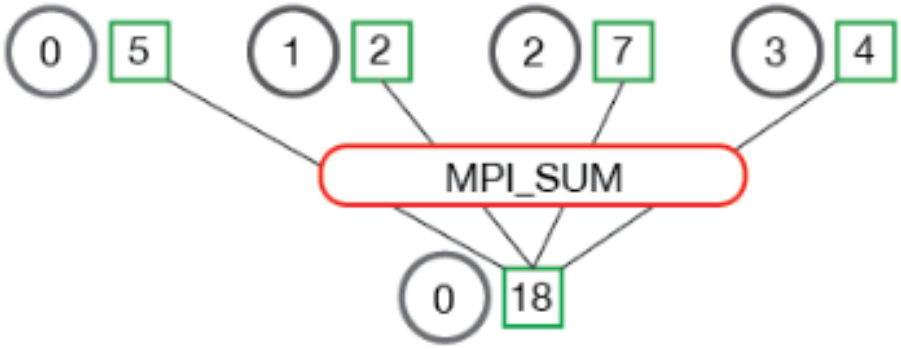

MPI_Allreduce

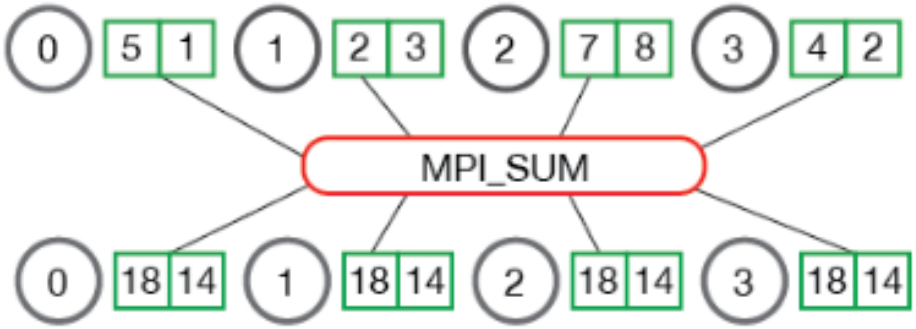

Operaciones colectivas en MPI

https://www.pinterest.es/pin/497577458813063755/

```
#include <stdio.h>
#include "mpi.h"

main (int argc, char **argv)
{
        int node,size;
        int tam = 255;
        char name[255];
        int num = 5;

        MPI_Init(&argc,&argv);
        MPI_Comm_size(MPI_COMM_WORLD, &size );
        MPI_Comm_rank(MPI_COMM_WORLD, &node );

        MPI_Bcast(&num, 1, MPI_INT, 0, MPI_COMM_WORLD);

        MPI_Barrier(MPI_COMM_WORD);
        printf("El proceso %d recibe %d\n",node, num);
        MPI_Finalize();
}
```

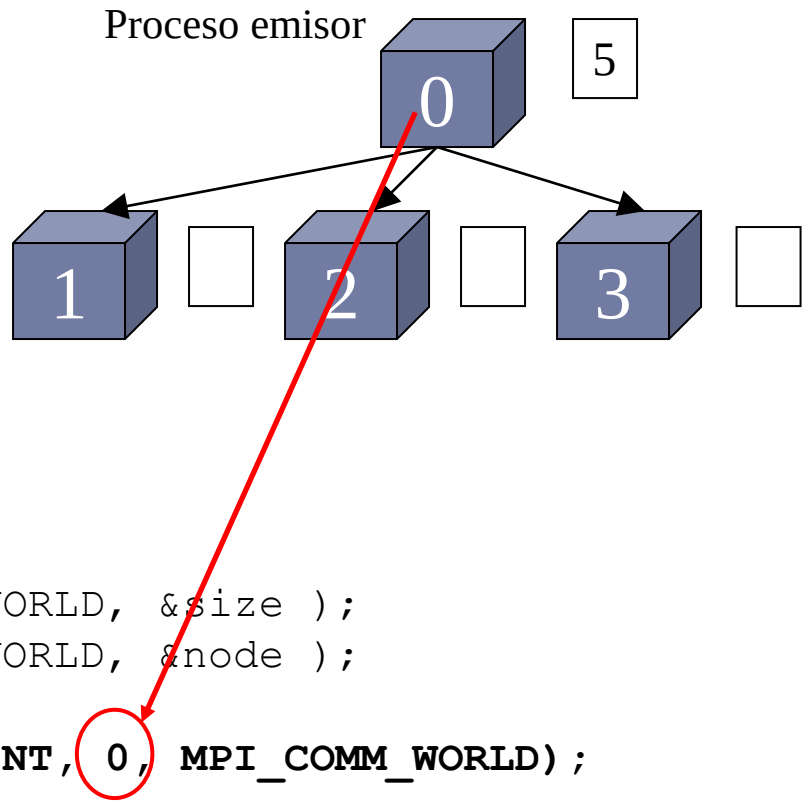

Operaciones colectivas en MPI

https://www.pinterest.es/pin/497577458813063755/

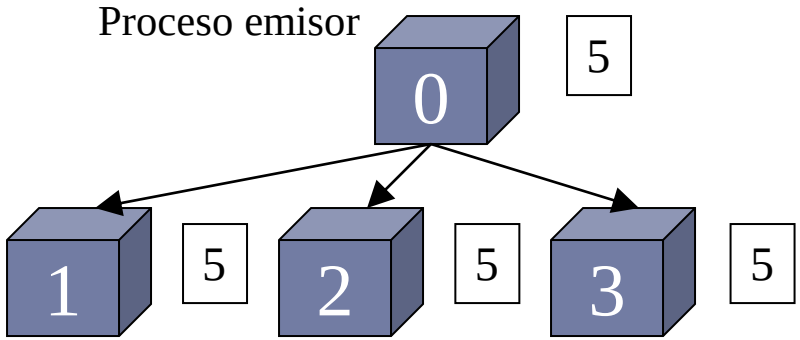


```
#include <stdio.h>
#include "mpi.h"

main (int argc, char **argv)
{
        int node,size;
        int tam = 255;
        char name[255];
        int num = 5;

        MPI_Init(&argc,&argv);
        MPI_Comm_size(MPI_COMM_WORLD, &size );
        MPI_Comm_rank(MPI_COMM_WORLD, &node );

        MPI_Bcast(&num, 1, MPI_INT, 0, MPI_COMM_WORLD);

        MPI_Barrier(MPI_COMM_WORD);
        printf("El proceso %d recibe %d\n",node, num);
        MPI_Finalize();
}
```

El resto de procesos reciben en num el mensaje enviado por el proceso 0

Ejemplo: Cálculo de π

https://www.pinterest.es/pin/497577458813063755/

$$\int_0^1 \sqrt{4\left(1-x^2\right)}\,dx = \frac{\pi}{2}$$

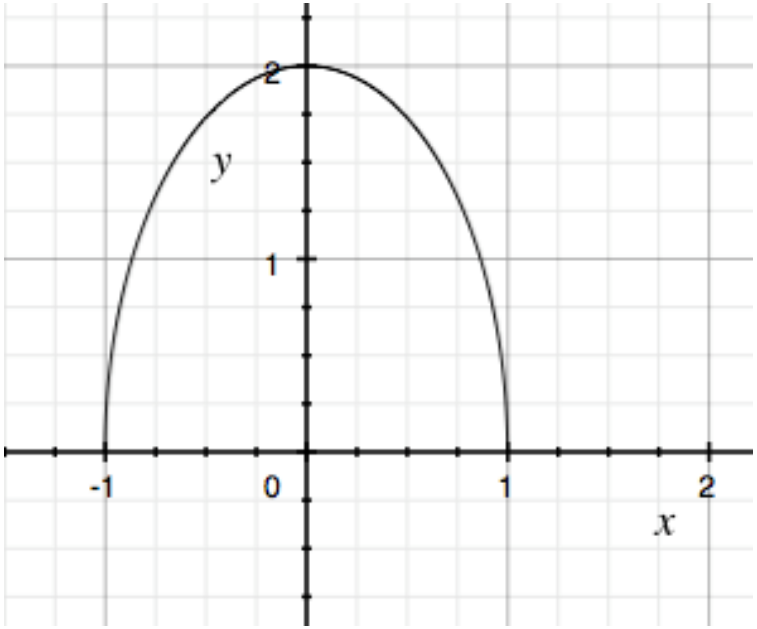

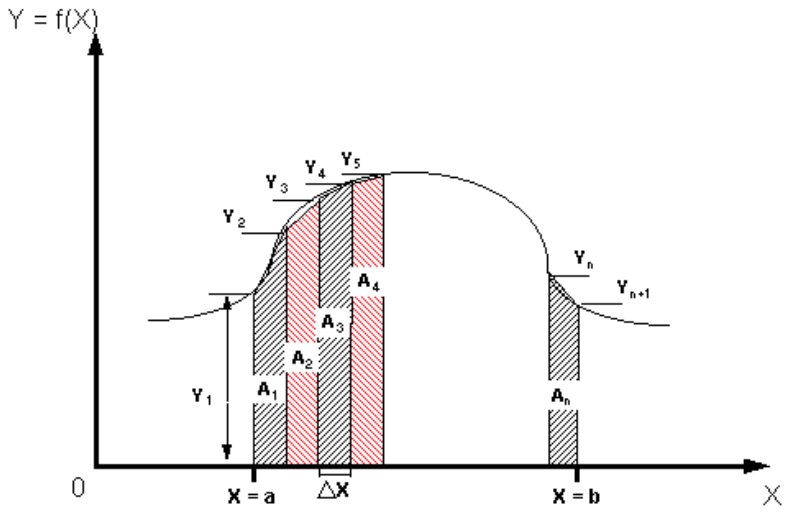

Cálculo secuencial

https://www.pinterest.es/pin/497577458813063755/

```
#include <stdio.h>
#include <math.h>
#include <stdio.h>

#define N 1E7
#define d 1E-7

int main (int argc, char* argv[]) {
    int i;
    double pi=0.0, result=0.0, sum=0.0, x2, x =0, s;

    result = 0;
    for (i=0; i<N; i++) {
        x2 = x * x;
        s = sqrt(1-x2) * d;
        result = result + s;
        x = x + d;
    }

    pi=4*result;
    printf("PI=%lf\n", pi);

    return 0;
}
```

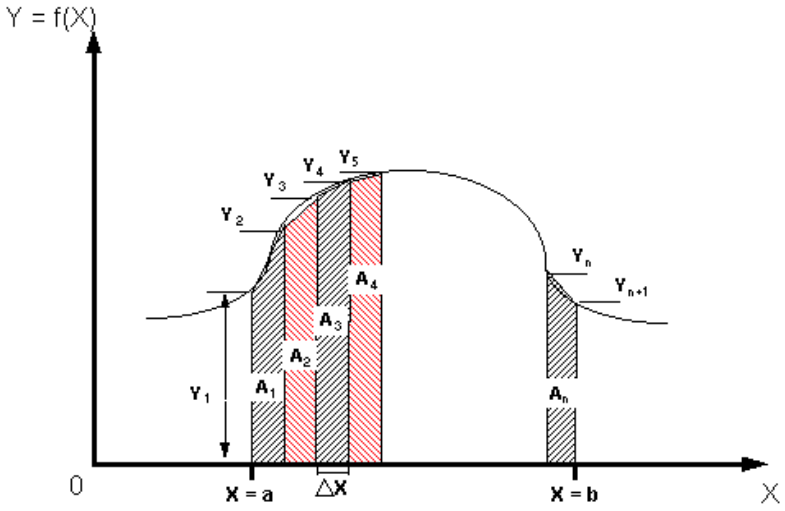

Cálculo paralelo

https://www.pinterest.es/pin/497577458813063755/

```
#include "mpi.h"
#include <math.h>

int main(int argc, char *argv[])
{
    int    n, myid, numprocs, i;
    double mypi, pi, h, sum, x;

    MPI_Init(&argc, &argv);
    MPI_Comm_size(MPI_COMM_WORLD, &numprocs);
    MPI_Comm_rank(MPI_COMM_WORLD, &myid);
    n   = 1000000 ; // number of intervals
    h   = 1.0 / (double) n;
    sum = 0.0;
    for (i = myid + 1; i <= n; i += numprocs) {
         x = h * ((double)i - 0.5);
         sum += 4.0 / (1.0 + x*x);
    }
    mypi = h * sum;
    MPI_Reduce(&mypi, &pi, 1, MPI_DOUBLE, MPI_SUM, 0, MPI_COMM_WORLD);
    if (myid == 0)
        printf("pi is approximately %.16f\n", pi);
    MPI_Finalize();
    return 0;
}
```

Plataforma hardware y software

SW

Aplicaciones paralelas

Entorno paralelo MPI/PVM

Aplicaciones secuenciales

Software de desarrollo
(compiladores y bibliotecas)

Software de gestión de recursos

Software de gestión de sistema
(instalación, administración, monitorización)

S.O. + servicios

HW

Supercomputador

Plataforma hardware y software

SW

Código C/C++, Fortran

MPICH2/OpenMPI

Código C, C++, Fortran

Compiladores de GNU, Intel, PGI
BLAS, LAPACK, ACML, etc.

PBS/Torque (*batch*) + MAUI (planificador)

SSH, C3Tools, IPMI, SNMP,
Ganglia, Nagios, etc.

Linux (NTP, DNS, DHCP, TFTP, LDAP/NIS, etc.)

Nativo, virtualizado

Gigabit, Infiniband, Myrinet

NFS, LUSTRE, GPFS, GFS, SAN

HW

Supercomputador

Top 500 Junio 2021

(http://www.top500.org)

Rank	Site	Cores	R_{max} (TFLOP/s)	R_{peak} (TFLOP/s)	Power (kW)
1	**Supercomputer Fugaku** - Supercomputer Fugaku, A64FX 48C 2.2GHz, Tofu interconnect D, Fujitsu RIKEN Center for Computational Science Japan	7,630,848	442,010.0	537,212.0	29,899
2	**Summit** - IBM Power System AC922, IBM POWER9 22C 3.07GHz, NVIDIA Volta GV100, Dual-rail Mellanox EDR Infiniband, IBM DOE/SC/Oak Ridge National Laboratory United States	2,414,592	148,600.0	200,794.9	10,096
3	**Sierra** - IBM Power System AC922, IBM POWER9 22C 3.1GHz, NVIDIA Volta GV100, Dual-rail Mellanox EDR Infiniband, IBM / NVIDIA / Mellanox DOE/NNSA/LLNL United States	1,572,480	94,640.0	125,712.0	7,438
4	**Sunway TaihuLight** - Sunway MPP, Sunway SW26010 260C 1.45GHz, Sunway, NRCPC National Supercomputing Center in Wuxi China	10,649,600	93,014.6	125,435.9	15,371
5	**Perlmutter** - HPE Cray EX235n, AMD EPYC 7763 64C 2.45GHz, NVIDIA A100 SXM4 40 GB, Slingshot-10, HPE DOE/SC/LBNL/NERSC United States	706,304	64,590.0	89,794.5	2,528
6	**Selene** - NVIDIA DGX A100, AMD EPYC 7742 64C 2.25GHz, NVIDIA A100, Mellanox HDR Infiniband, Nvidia NVIDIA Corporation United States	555,520	63,460.0	79,215.0	2,646
7	**Tianhe-2A** - TH-IVB-FEP Cluster, Intel Xeon E5-2692v2 12C 2.2GHz, TH Express-2, Matrix-2000, NUDT National Super Computer Center in Guangzhou China	4,981,760	61,444.5	100,678.7	18,482
8	**JUWELS Booster Module** - Bull Sequana XH2000 , AMD EPYC 7402 24C 2.8GHz, NVIDIA A100, Mellanox HDR InfiniBand/ParTec ParaStation ClusterSuite, Atos Forschungszentrum Juelich (FZJ) Germany	449,280	44,120.0	70,980.0	1,764
9	**HPC5** - PowerEdge C4140, Xeon Gold 6252 24C 2.1GHz, NVIDIA Tesla V100, Mellanox HDR Infiniband, Dell EMC Eni S.p.A. Italy	669,760	35,450.0	51,720.8	2,252
10	**Frontera** - Dell C6420, Xeon Platinum 8280 28C 2.7GHz, Mellanox InfiniBand HDR, Dell EMC Texas Advanced Computing Center/Univ. of Texas United States	448,448	23,516.4	38,745.9	

Top 500
(country=es)

- Junio 2014

Rank	Site	System	Cores	Rmax (TFlop/s)	Rpeak (TFlop/s)	Power (kW)
41	Barcelona Supercomputing Center Spain	**MareNostrum** - iDataPlex DX360M4, Xeon E5-2670 8C 2.600GHz, Infiniband FDR, IBM	48,896	925.1	1,017.0	1,015.6
168	Instituto Tecnológico y de Energías Renovables S.A. Spain	**TEIDE-HPC** - Fujitsu PRIMERGY CX250 S1, Xeon E5-2670 8C 2.600GHz, Infiniband QDR, Fujitsu	16,384	274.0	340.8	312

- Junio 2015

77	Barcelona Supercomputing Center Spain	**MareNostrum** - iDataPlex DX360M4, Xeon E5-2670 8C 2.600GHz, Infiniband FDR, IBM	48,896	925.1	1,017.0	1,015.6
259	Instituto Tecnológico y de Energías Renovables S.A. Spain	**TEIDE-HPC** - Fujitsu PRIMERGY CX250 S1, Xeon E5-2670 8C 2.600GHz, Infiniband QDR, Fujitsu	16,384	274.0	340.8	312

- Junio 2017

13	Barcelona Supercomputing Center Spain	**MareNostrum** - Lenovo SD530, Xeon Platinum 8160 24C 2.1GHz, Intel Omni-Path , Lenovo	148,176	6,227.2	9,957.4	1,380

- Junio ~~2020~~ ~~2021~~ ~~2022~~ 2023

~~37~~ ~~63~~ ~~82~~ 98	Barcelona Supercomputing Center Spain	**MareNostrum** - Lenovo SD530, Xeon Platinum 8160 24C 2.1GHz, Intel Omni-Path , Lenovo	153,216	6,470.8	10,296.1	1,632

Top 500 Junio 2023

(http://top500.org/statistics/perfdevel/)

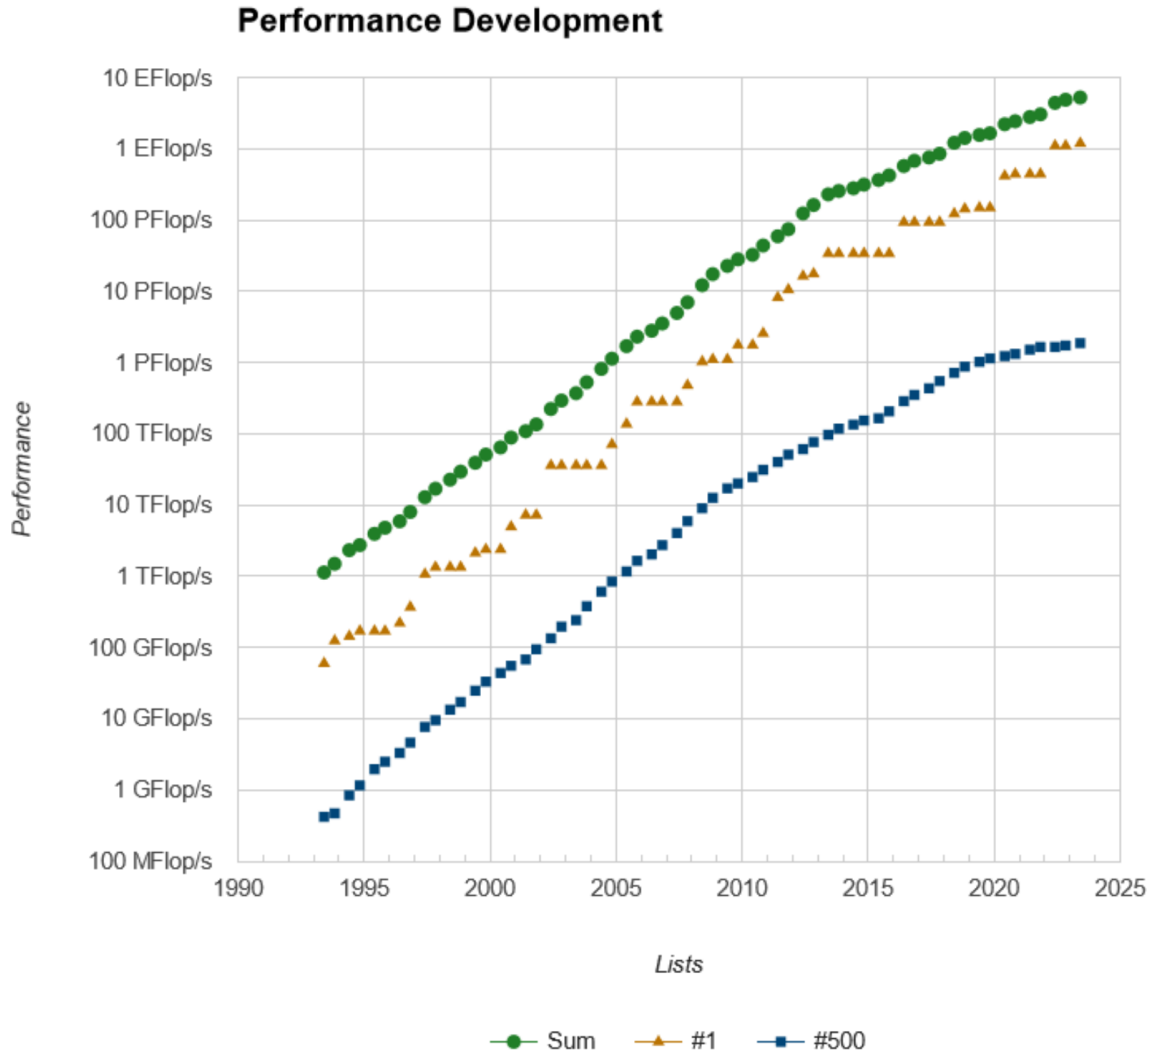

Top 500 Junio 2023

(http://top500.org/statistics/perfdevel/)

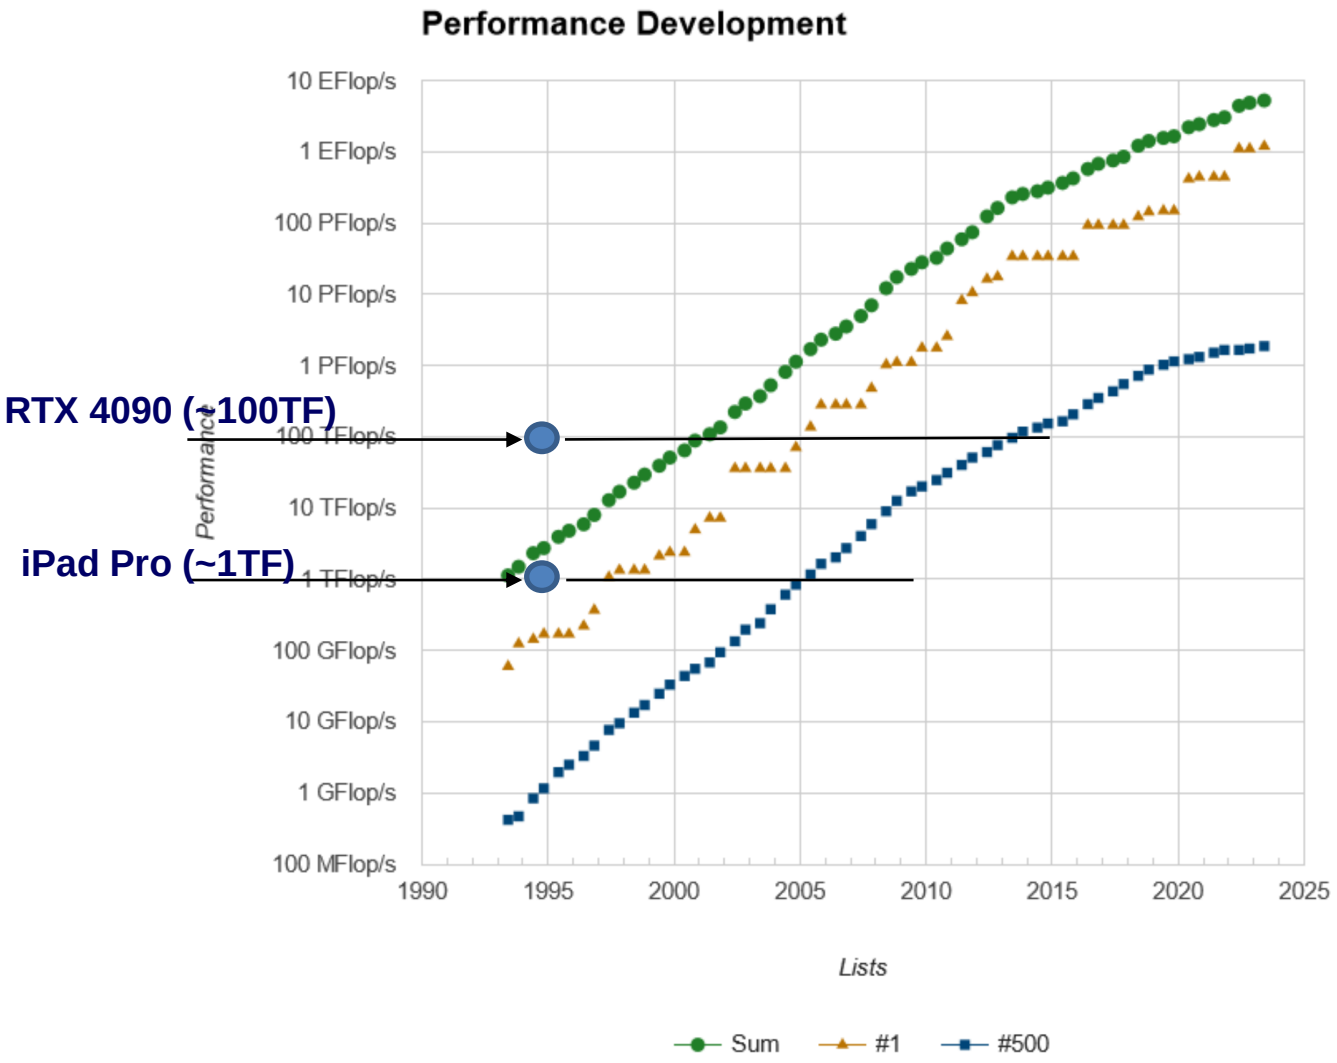

Agenda

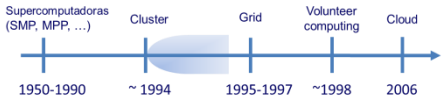

Introducción a la computación de altas prestaciones

- Qué, dónde y cómo
- Hardware y software

Evolución de la computación de altas prestaciones

- Plataformas
- Tendencias

Evolución en las plataformas de computación de altas prestaciones

- Problemas con gran cantidad de cómputo
- Más usado en ciencia y ejército
- Uso de paralelismo masivo

Supercomputadoras
(SMP, MPP, Sistólico, Array, …)

1950-1990

Evolución en las plataformas de computación de altas prestaciones

- Problemas con gran cantidad de datos tratados
- Más usado en administración
- Uso de paralelismo y alta frecuencia

Supercomputadoras & Mainframes
(SMP, MPP, Sistólico, Array, …)

1950-1990

Evolución en las plataformas de computación de altas prestaciones

- Construido por Donald Becker y Thomas Sterling en 1994 (NASA)
- Formado por 16 computadores personales con procesador intel DX4 a 200 MHz interconectados por un switch Ethernet.
- Rendimiento teórico era de 3,2 Gflops
- Posibilidad de supercomputadoras ”baratas”

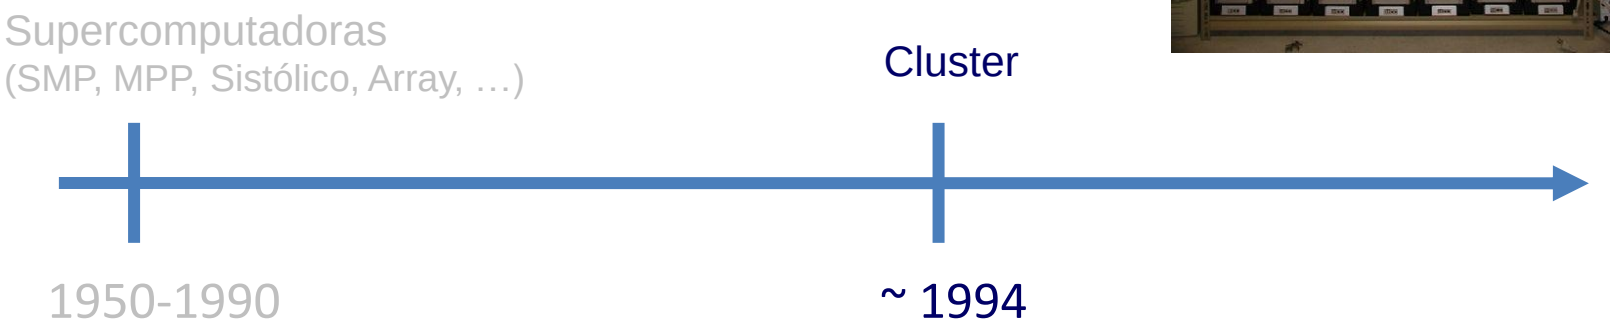

Evolución en las plataformas de computación de altas prestaciones

- Construido por Donald Becker y Thomas Sterling en 1994 (NASA)
- Formado por 16 computadores personales con procesador intel DX4 a 200 MHz interconectados por un switch Ethernet.
- Rendimiento teórico era de 3,2 Gflops
- Posibilidad de supercomputadoras ”baratas”

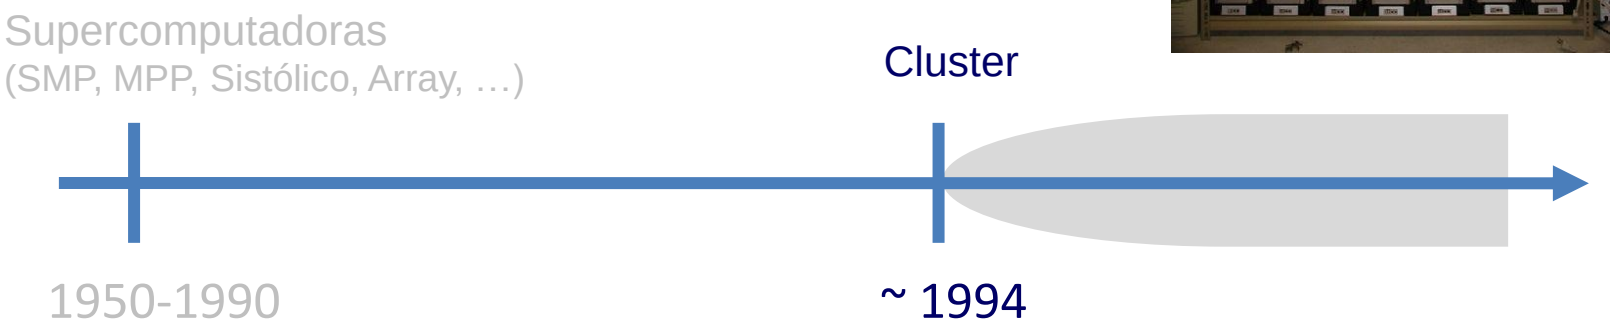

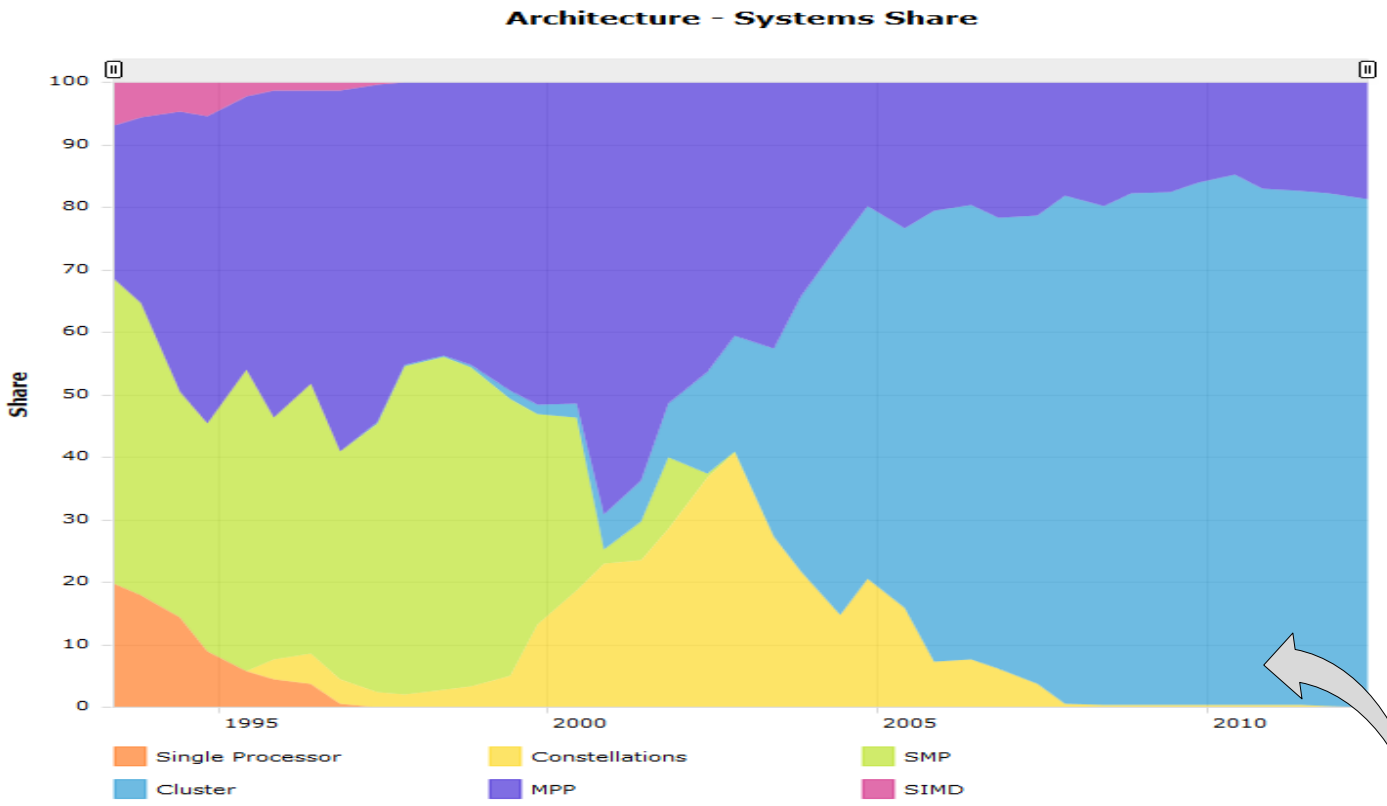

Supercomputadoras
(SMP, MPP, Sistólico, Array, …)

Cluster

1950-1990

~ 1994

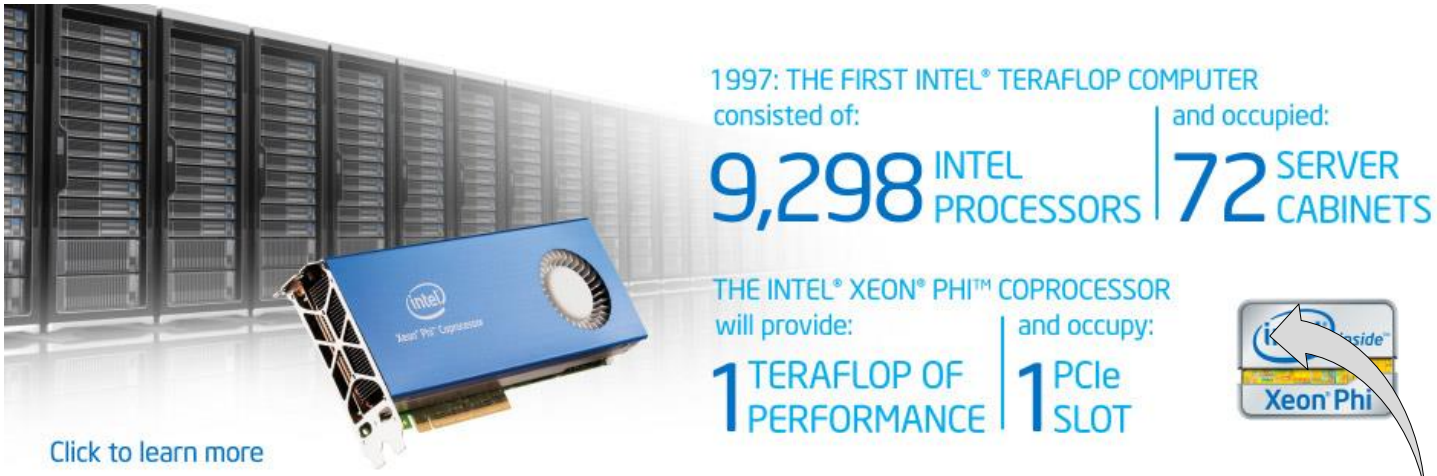

Supercomputadoras
(SMP, MPP, Sistólico, Array, …)

Cluster

1950-1990

~ 1994

http://es.wikipedia.org/wiki/Intel_MIC

Evolución en las plataformas de computación de altas prestaciones

- Antecesor: metacomputing por Larry Smarr (NCSA) al inicio de los 80
  - Centros de supercomputación interconectados: más recursos disponibles
  - I-WAY demostrado en 1995
- Grid aparece en un seminario dado en 1997 en ANL por Ian Foster y Carl Kesselman

Evolución en las plataformas de computación de altas prestaciones

- Término acuñado por Luis F. G. Sarmenta (Bayanihan)
- En 1999 se lanza los proyectos SETI@home y Folding@home
- A día 26/09/2021 todos los proyectos BOINC suponen ~22275 TeraFLOPS

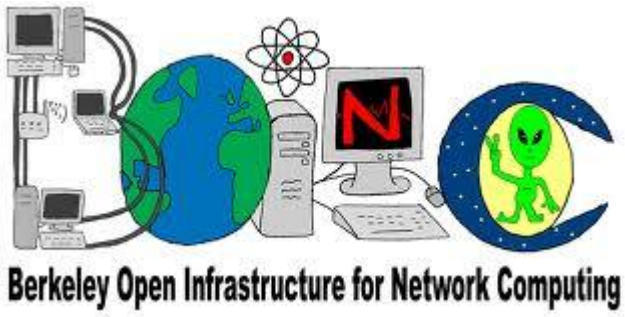

http://boincstats.com/es/stats/-1/project/detail

Evolución en las plataformas de computación de altas prestaciones

Doug Cutting y Hadoop

- Google presenta:
  - MapReduce como *framework* para trabajar con grandes conjuntos de datos: la misma función se aplica a diferentes particiones de datos (map) y después estos resultados se combinan (reduce)
  - GFS como forma de almacenar petabytes de datos (ordenadores normales, distribución escalable y tolerancia a fallos)
- GFS+MR permite a los usuarios construir "mainframes baratos" (GFS+MR vs mainframe similar a cluster vs supercomputador)

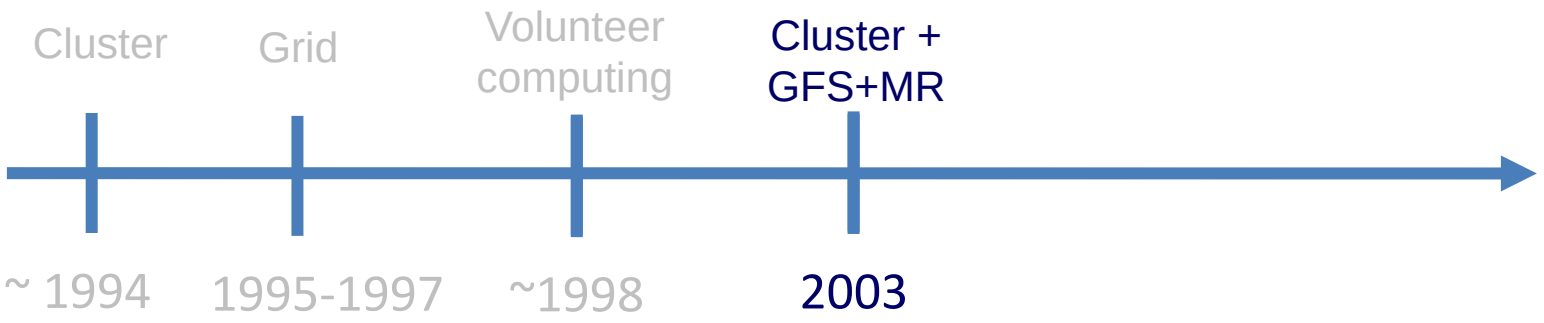

Evolución en las plataformas de computación de altas prestaciones

- Amazon inspira el *Cloud computing* actual:
  - *data centers* pensando en las compras de Navidad, el resto del tiempo se usaban ~10%
  - Dos pilares fundamentales: *utility computing* y virtualización
- Principales mejoras: agilidad, coste, escalabilidad, mantenimiento, …
- Openstack: construir un *cloud* con un cluster

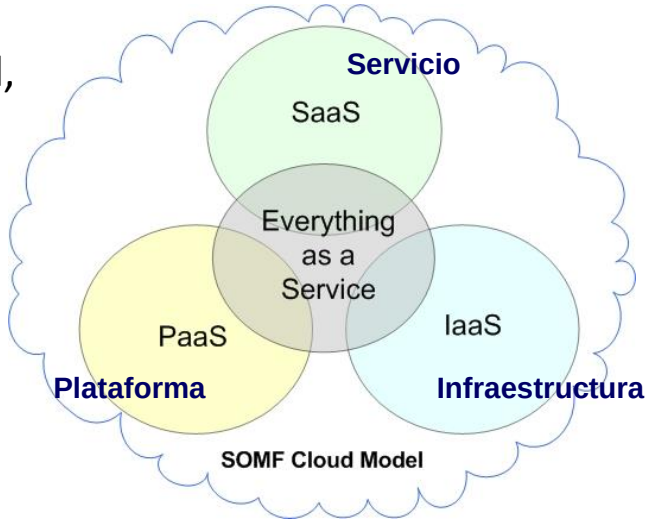

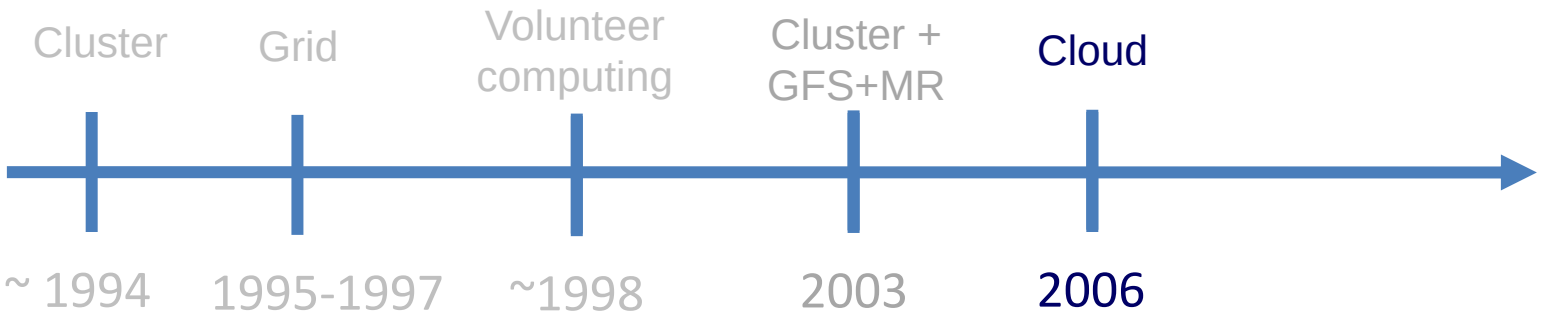

Amazon Cluster Compute Instance

Tightly coupled

Network placement groups

Cluster instances deployed in a Placement Group enjoy low latency, full bisection 10 Gbps bandwidth

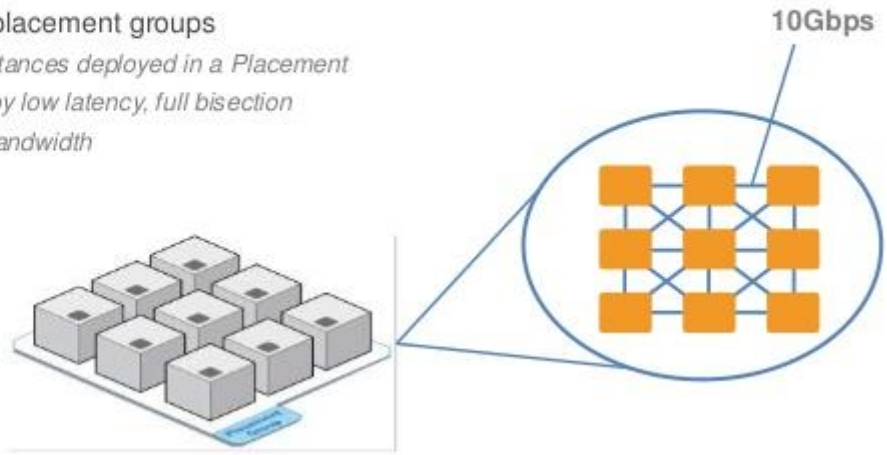

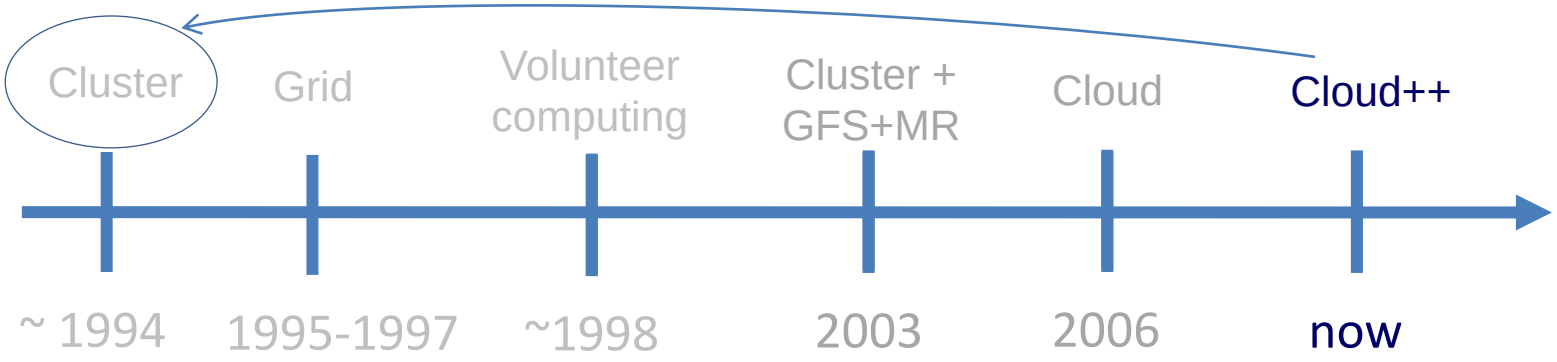

Amazon Elastic MapReduce

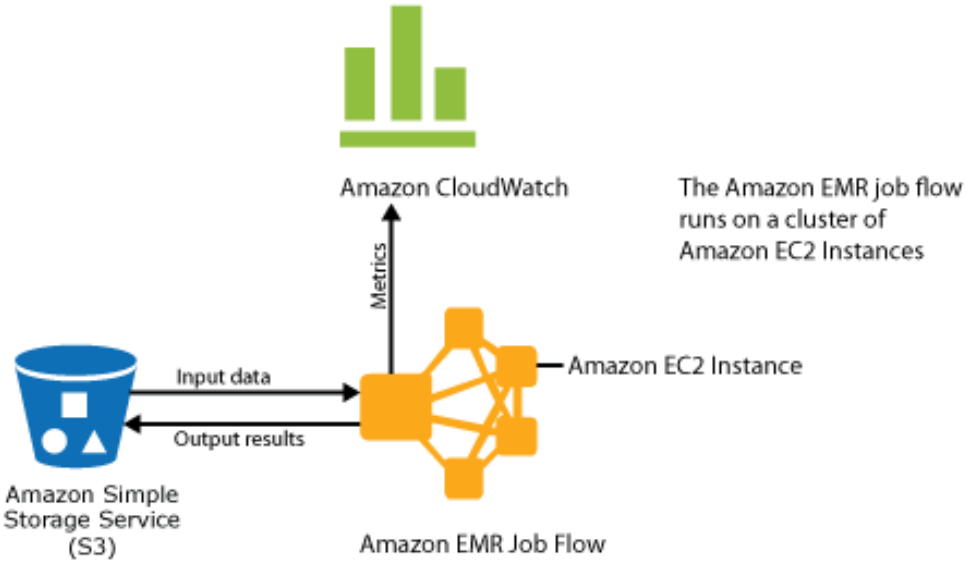

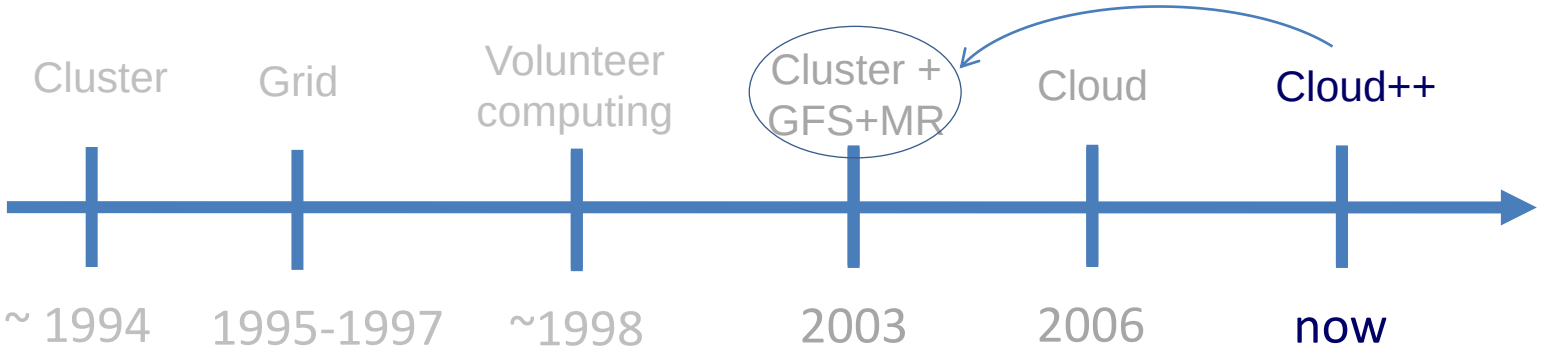

Nvidia DGX-320G

(https://www.nvidia.com/es-es/data-center/dgx-2/)

https://wccftech.com/nvidia-dgx-station-320g-quad-ampere-a100-gpus-with-320-gb-memory/

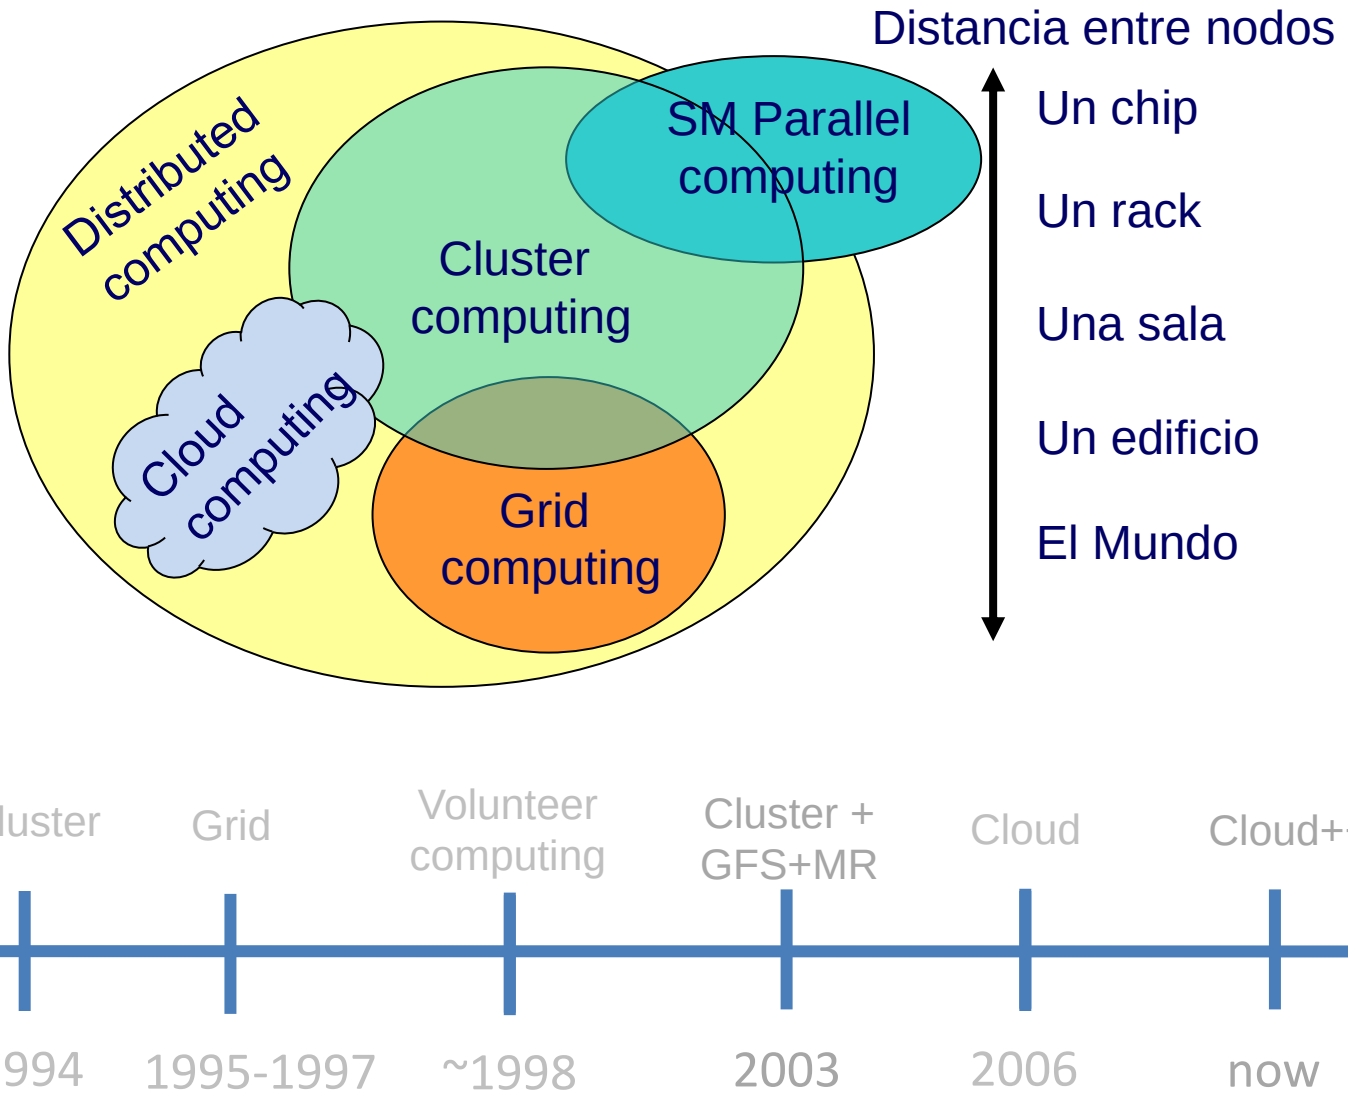
Distancia entre nodos
Un chip
Un rack
Una sala
Un edificio
El Mundo
Distributed computing
SM Parallel computing
Cluster computing
Cloud computing
Grid computing
Cluster
Grid
Volunteer computing
Cluster + GFS+MR
Cloud
Cloud++
~ 1994
1995-1997
~1998
2003
2006
now

Agenda

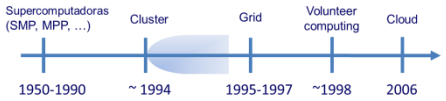

Introducción a la computación de altas prestaciones
- Qué, dónde y cómo
- Hardware y software

Evolución de la computación de altas prestaciones
- Plataformas
- Tendencias

Principales tendencias

Supercomputadoras (SMP, MPP, …)

Cluster

Grid

Volunteer computing

Cloud

Plataforma →

Aplicaciones paralelas	Aplicaciones secuenciales
Entorno paralelo	
Middleware (*Single System Image*)	
S.O. + servicios	

Software →

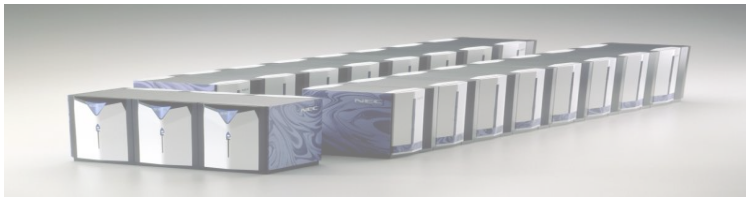

Computador de altas prestaciones

Hardware →

Principales tendencias

Supercomputadoras (SMP, MPP, …)

Cluster

Grid

Volunteer computing

Cloud

Plataforma →

Aplicaciones paralelas

Entorno paralelo

Aplicaciones secuenciales

Middleware (*Single System Image*)

S.O. + servicios

Software →

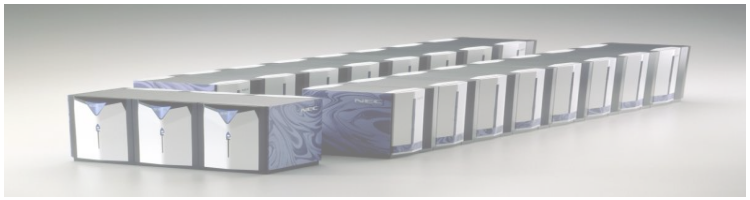

Computador de altas prestaciones

Hardware →

Plataforma:

uso de recursos distribuidos

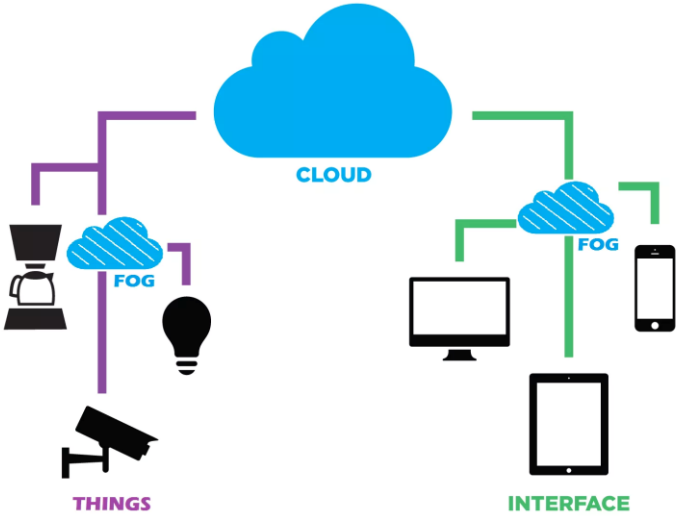

- **Clouds**: empleo de recursos distribuidos alquilados bajo demanda
- **Fog/Edge**: acercar el cloud a los dispositivos que lo usan

https://iot.do/ngd-openfog-fog-computing-2016-10

Plataforma:

uso eficiente de recursos

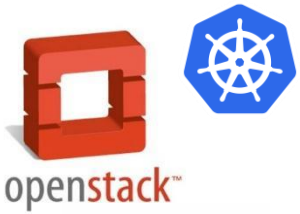

- **Clouds privados y públicos**: ajuste de infraestructura para minimizar gasto

- **Green computing**: uso de recursos distribuidos de distintas organizaciones

- **Internet computing**: uso de ordenadores personales a escala global (SETI@home)

Principales tendencias

Supercomputadoras (SMP, MPP, …)

Cluster

Grid

Volunteer computing

Cloud

Plataforma →

Aplicaciones paralelas

Entorno paralelo

Aplicaciones secuenciales

Middleware (*Single System Image*)

S.O. + servicios

Software →

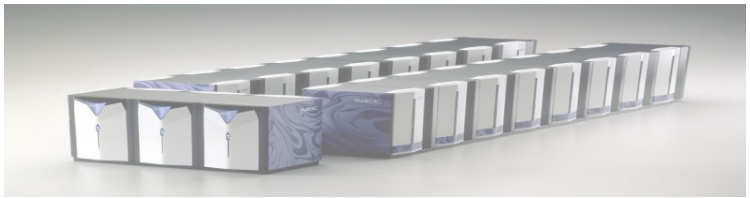

Computador de altas prestaciones

Hardware →

Hardware

A nivel de multicomputador

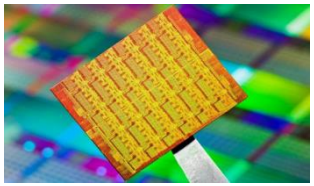

A nivel de procesador

A nivel de instrucción

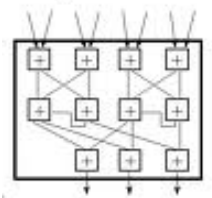

A nivel de bit

Hardware

A nivel de multicomputador

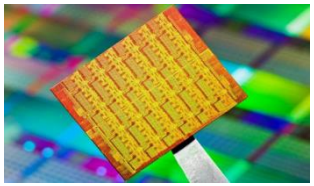

A nivel de procesador

A nivel de instrucción

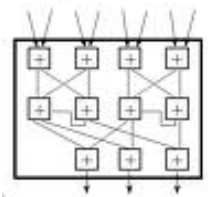

A nivel de bit

Hardware:

más procesadores y cores heterogéneos

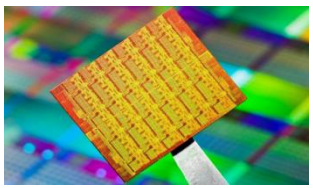

A nivel de procesador

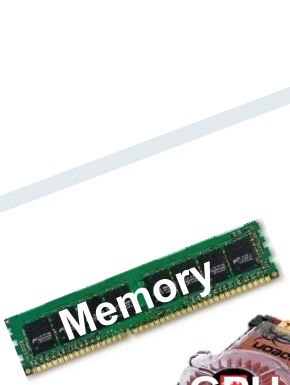

Hardware multicore

Hardware específico

A nivel de multicomputador

Hardware:

más procesadores y cores heterogéneos

- **Tarjetas gráficas**: uso de la capacidad de procesamiento de las potentes tarjetas gráficas actuales

Hardware:

más procesadores y cores heterogéneos

- **Tarjetas gráficas**: uso de la capacidad de procesamiento de las potentes tarjetas gráficas actuales
  - CUDA:
    Entorno de programación para poder usar la potencia de las tarjetas gráficas de NVidia
  - OpenCL:
    lenguaje basado en C99 extendido para operaciones vectoriales y eliminando ciertas funcionalidades

Hardware:

más procesadores y cores heterogéneos

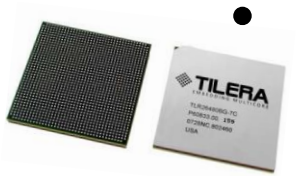

- **Procesadores many-core**: gran cantidad de procesadores en un mismo chip

- http://gizmodo.com/5846060/this-crazy-64+core-processor-wants-to-be-in-your-smartphone
- http://www.tgdaily.com/hardware-features/33451-tilera-announces-64-core-processor

Hardware:
más procesadores y cores heterogéneos

- **Procesadores many-core**: gran cantidad de procesadores en un mismo chip

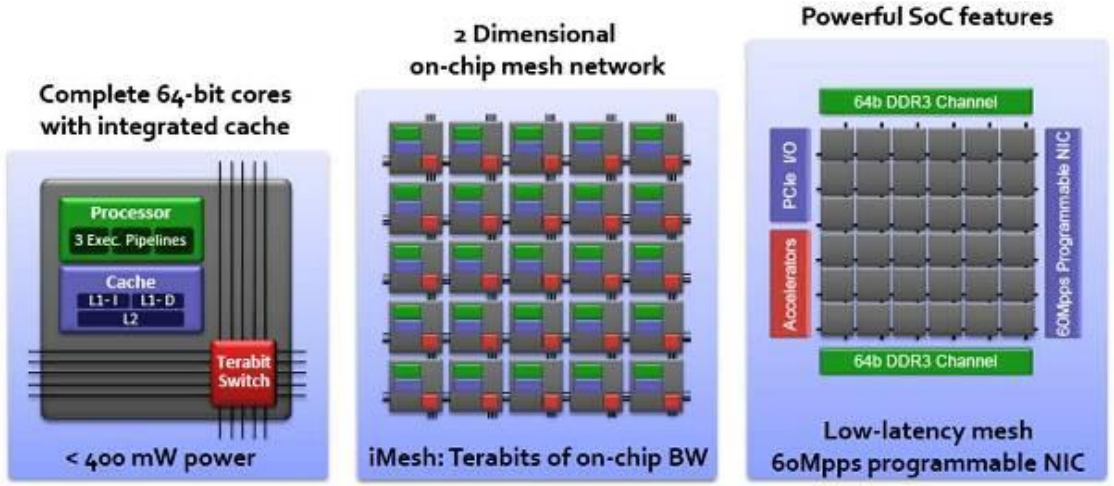

- http://www.electroiq.com/articles/sst/2012/01/40nm-manycore-processors-roll-out-at-tilera.html

Hardware:
más procesadores y cores heterogéneos

- **Procesadores many-core**: gran cantidad de procesadores en un mismo chip
  - <memoria compartida>:
    SMP Linux 2.6
  - <paso de mensaje>:
    Hypervisor (VMs)

- http://www.tilera.com/development_tools

Hardware:
más procesadores y cores heterogéneos

- **Procesadores heterogéneos**:
  gran cantidad de procesadores con coprocesadores especializados

- http://es.wikipedia.org/wiki/Intel_MIC
- http://hothardware.com/News/Intel-Demos-Knights-Ferry-Development-Platform-Tesla-Scores-With-Amazon/

Hardware:
más procesadores y cores heterogéneos

- **Procesadores heterogéneos**:
  gran cantidad de procesadores con coprocesadores especializados
  - <memoria compartida>:
    Intel Cilk (plus), Intel Threading Building Blocks, OpenMP, ¿OpenACC?, OpenCL
  - <paso de mensaje>:
    Intel MPI

- http://goparallel.sourceforge.net/parallel-programming-intel-mic-early-experiences-tacc/
- http://www.drdobbs.com/parallel/intels-50-core-mic-architecture-hpc-on-a/232800139

Hardware:

más procesadores y cores heterogéneos

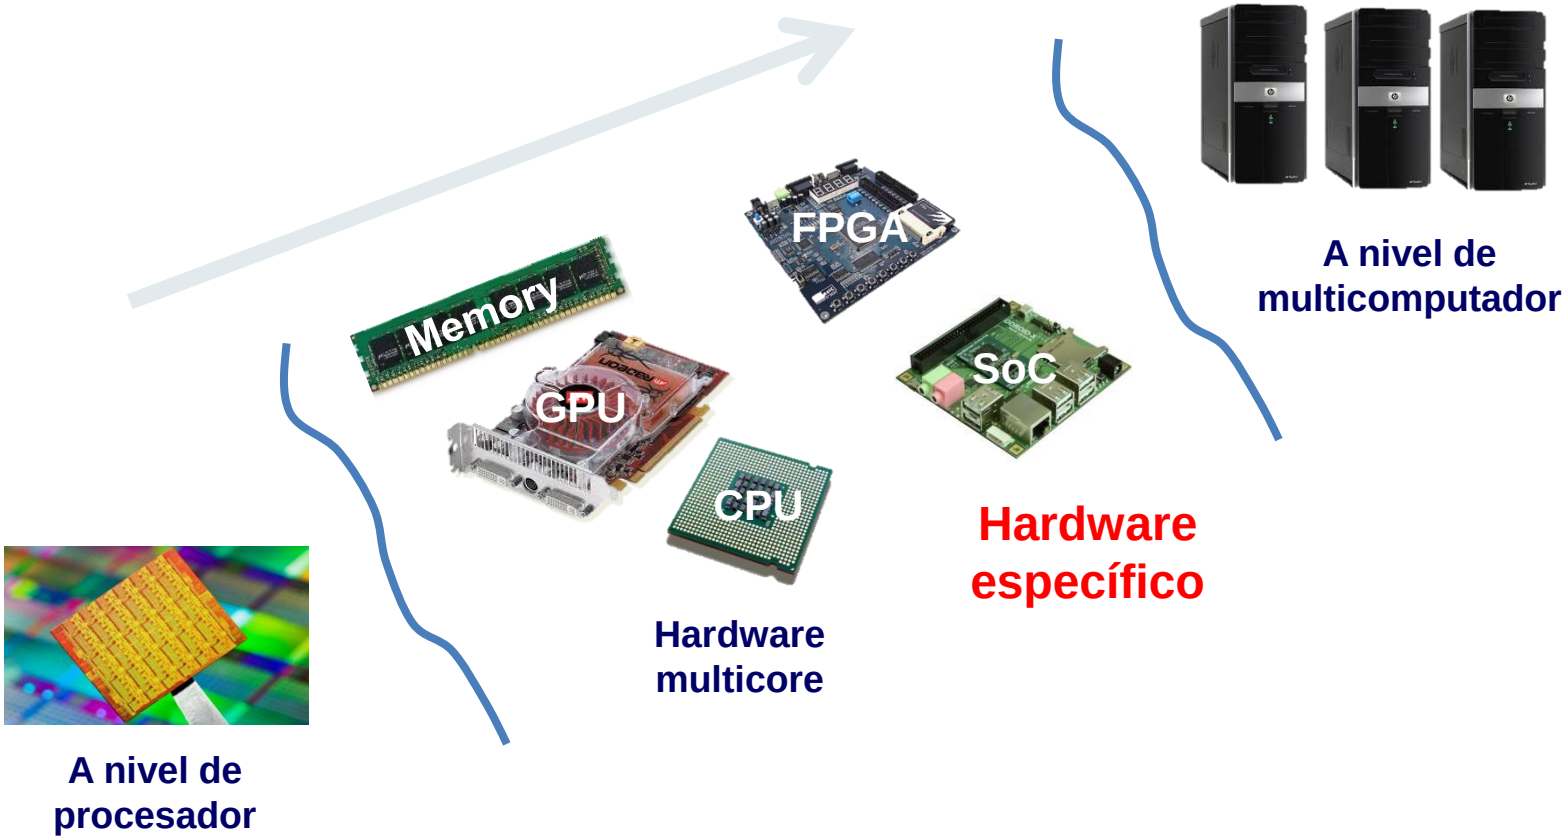

Hardware:

memoria persistente, de gran capacidad y baja latencia

- **Memoria 3D-XPoint**:

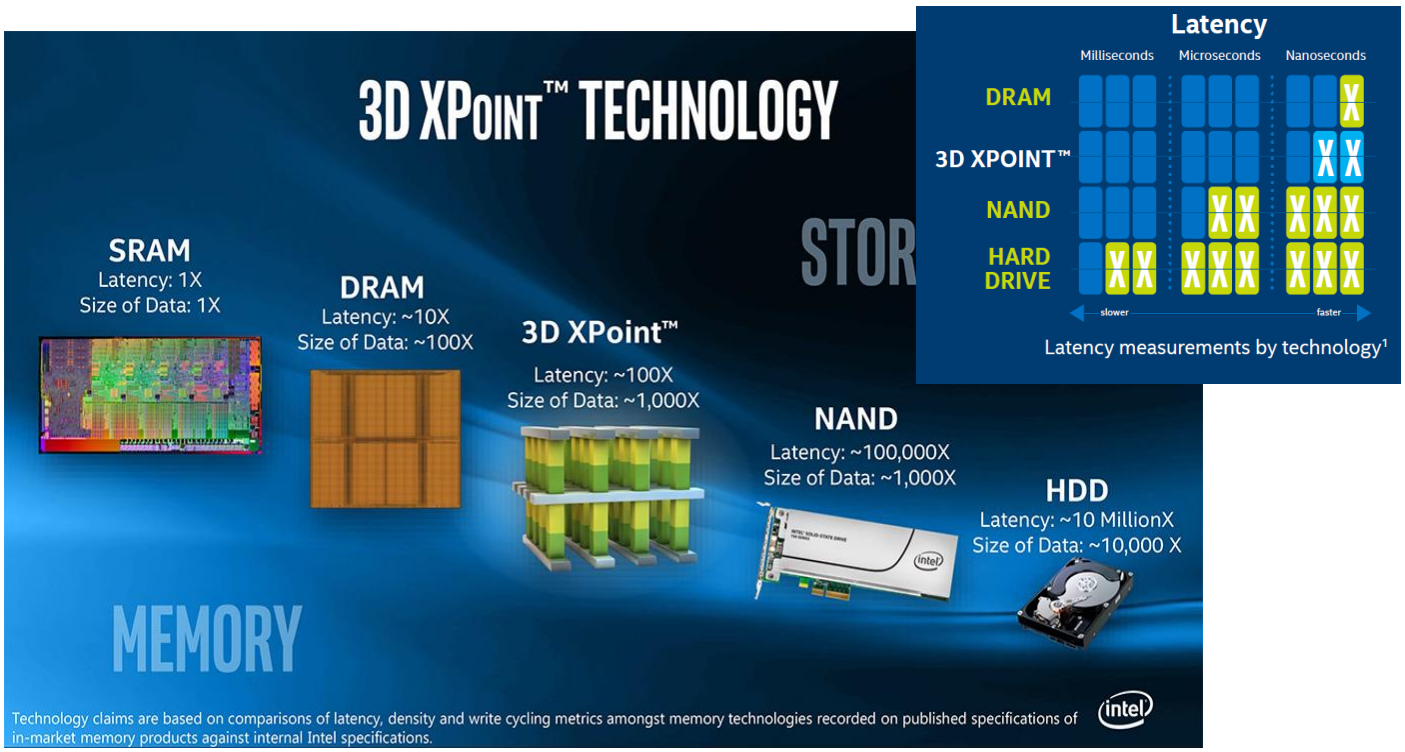

- http://www.golem.de/news/3d-xpoint-neuer-speicher-wird-als-ddr-modul-oder-pcie-karte-eingesetzt-1508-115728.html

Hardware:

”memoria” con capacidad de cómputo

- **Memoria “activa”**:
  computo simple en la propia memoria

Planted Motif Search Problem	Automata Processor	UCONN - BECAT Hornet Cluster
Processors	48 (PCIe Board)+CPU	48 CPU (Cluster/OpenMPI)
Power	245W-315W[1]	>2,000W[1]
Cost	TBD	~$20,000[1]
Performance (25,10)	12.26 minutes[2]	20.5 minutes
Performance (26,11)	13.96 minutes[2]	46.9 hours
Performance (36,16)	36.22 minutes[2]	Unsolved

- Planted Motif Search problem is a leading problem in bioinformatics and is NP Hard. Attempts to find common genomic sequences in noisy data.
- Solutions involving high match lengths and substitution counts are often presented to HPC clusters for processing.
- Independent research predicts the Micron Automata Processor significantly outperforms a multi-core HPC cluster in speed, power and estimated cost.

[1] Micron Technology Estimates, Not including Memory of 4GB DRAM /Core
[2] Research conducted by Georgia Tech (Roy/Aluru)

- http://www.hpcwire.com/2013/11/22/micron-exposes-memorys-double-life-automata-processor/

Hardware:

aceleradores específicos por USB

- Conector USB Type A.
- VPU (Vision Processing Unit) Myriad 2.
- 4 GB de memoria LPDDR3.
- Soporte del framework “Caffe”.
- Compatible con FP16 (precisión media).
- Consumo de 1 vatio.
- Precio: **79 dólares** (2017)

- https://www.muycomputer.com/2017/07/20/movidius-neural-compute-stick/
- https://www.movidius.com/MyriadX

Hardware:

qubit-chip

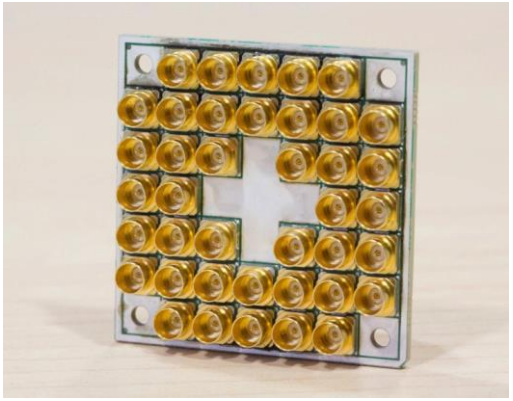

- "…While quantum computers promise greater efficiency and performance to handle certain problems, they won't replace the need for conventional computing or other emerging technologies like neuromorphic computing. We'll need the technical advances that Moore's law delivers in order to invent and scale these emerging technologies…"

- https://newsroom.intel.com/news/intel-delivers-17-qubit-superconducting-chip-advanced-packaging-qutech/

Principales tendencias

Supercomputadoras (SMP, MPP, …)

Cluster

Grid

Volunteer computing

Cloud

Plataforma →

Aplicaciones paralelas

Entorno paralelo

Aplicaciones secuenciales

Middleware (*Single System Image*)

S.O. + servicios

Software →

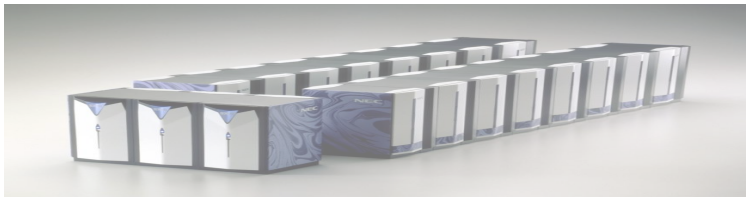

Computador de altas prestaciones

Hardware →

Software

Vectoriales
SSE, AVX, AVX2, …

Multiprocesador
UMA, NUMA
OpenMP,
iTBB, …

M. Distribuida
MPI,…
Map-reduce

- **Integrar soluciones vectoriales y multiprocesador (dentro de las herramientas de desarrollo)**

Ejemplo:

CUDA/LLVM adaptado a nuevos entornos

- CUDA Compiler SDK
- Versión de Clang/LLVM con:
  - Generación de código para GPU
  - Compilación con CUDA
- Soporte para:
  - MacOS
  - Windows
  - Linux (algunos)

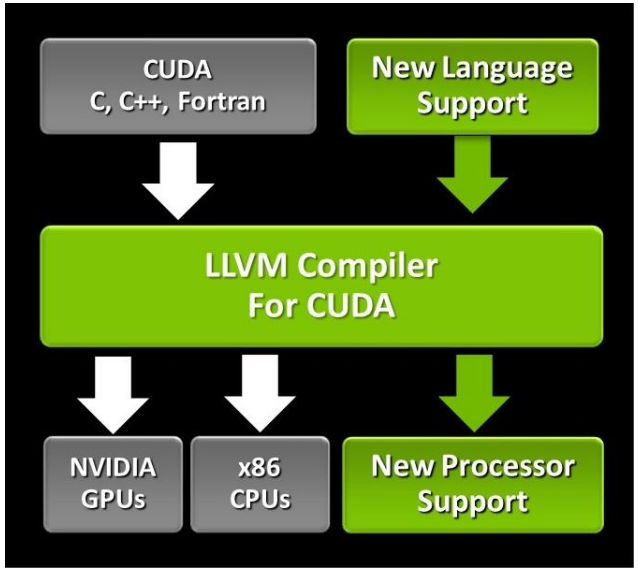

- http://developer.nvidia.com/cuda/cuda-llvm-compiler

Software

Vectoriales
SSE, AVX, AVX2, …

Multiprocesador
UMA, NUMA
OpenMP,
iTBB, …

M. Distribuida
MPI,…
Map-reduce

- Integrar soluciones vectoriales y multiprocesador (dentro de las herramientas de desarrollo)
- **Integrar soluciones de memoria compartida y paso de mensaje con ayuda del sistema operativo.**

Ejemplo:

MPI 3.x: adaptación a requisitos actuales

- Programación híbrida
- Tolerancia a fallos
- Acceso remoto a memoria
- Comunicación colectiva y topología
- Soporte de herramientas
- Persistencia
- Compatibilidad hacia atrás

- http://meetings.mpi-forum.org/MPI_3.0_main_page.php

Software

Vectoriales

SSE, AVX, AVX2, …

Multiprocesador

UMA, NUMA

OpenMP,

iTBB, …

M. Distribuida

MPI,…

Map-reduce

- Integrar soluciones vectoriales y multiprocesador (dentro de las herramientas de desarrollo)
- Integrar soluciones de memoria compartida y paso de mensaje con ayuda del sistema operativo.
- **Buscar perfiles simplificados que permitan la mayor escalabilidad posible.**

Sistemas distribuidos:

Computación de altas prestaciones

- Google:
  - Modelo MapReduce

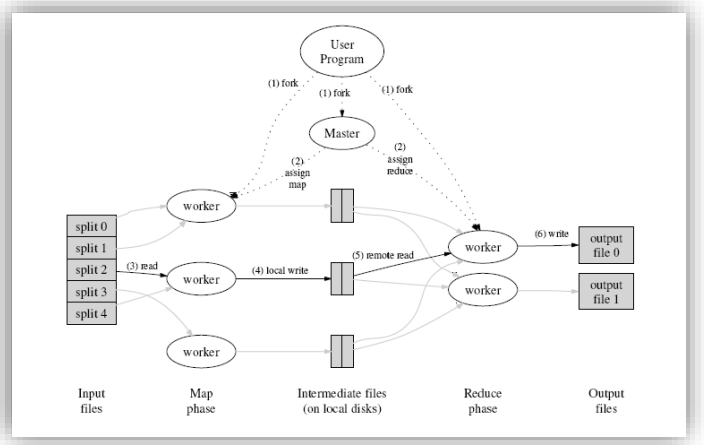

  - Sistemas de ficheros de Google
  - Algoritmos de clasificación (K-Means + Canopy)

- http://code.google.com/edu/parallel/mapreduce-tutorial.html
- http://code.google.com/edu/submissions/mapreduce-minilecture/listing.html
- http://en.wikipedia.org/wiki/MapReduce

Aplicaciones:

Adaptación a computación de altas prestaciones

- Ejemplos:
  - Primal and dual-based algorithms for sensing range adjustment in WSNs
  - The unified accelerator architecture for RNA secondary structure prediction on FPGA
  - Protein simulation data in the relational model
  - Dynamic learning model update of hybrid-classifiers for intrusion detection

- http://www.springer.com/computer/swe/journal/11227

Agenda

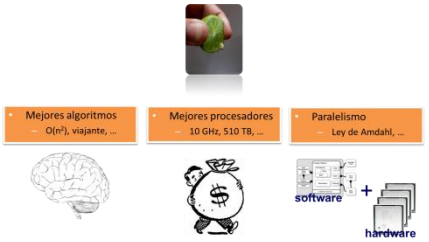

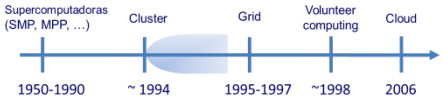

Introducción a la computación de altas prestaciones

- Qué, dónde y cómo
- Hardware y software

Evolución de la computación de altas prestaciones

- Plataformas
- Tendencias

Bibliografía

- **Parallel Computer Architectures: a Hardware/Software Approach.**
  D.E. Culler, J.P. Singh, with A. Gupta
  - Capítulo 1

- **Organización y Arquitectura de Computadores (5ta. ed.)**
  William Stallings
  - Capítulo 16: Procesamiento Paralelo.

- **Organización de Computadoras (4ta. ed.)**
  Andrew S. Tanenbaum
  - Capítulo 8: Arquitecturas de computadoras paralelas.

Bibliografía

- **GPU + CPU**
  - http://www.hardwarezone.com.ph/articles/view.php?cid=3&id=2786
- **Cluster**
  - http://www.democritos.it/~baro/slides/LAT-HPC-GRID-2009/Part1.pdf
- **TOP500 Supercomputer Sites**
  - http://www.top500.org/
- **Beowulf**
  - http://www.beowulf.org/overview/index.html

Sistemas Paralelos y Distribuidos

Máster en Ciencia y Tecnología Informática

Máster Universitario en Matemática Aplicada y Computacional

Curso 2023-2024

Sistemas de altas prestaciones en entornos distribuidos

Alejandro Calderón Mateos y Félix García Carballeira

Grupo de Arquitectura de Computadores

alejandro.calderon@uc3m.es